UNIVERSIDAD POLITÉCNICA DE MADRID

ESCUELA TÉCNICA SUPERIOR
DE INGENIEROS DE TELECOMUNICACIÓN

GRADO EN INGENIERÍA DE TECNOLOGÍAS Y SERVICIOS DE TELECOMUNICACIÓN

TRABAJO FIN DE GRADO

Desarrollo y evaluación de un sistema de identificación de notas a partir de interpretaciones de piano

MARGARITA LÓPEZ RAMOS

2024

GRADO EN INGENIERIA DE TECNOLOGÍAS Y SERVICIOS DE TELECOMUNICACION

TRABAJO FIN DE GRADO

Título: Desarrollo y evaluación de un sistema de identificación de notas a partir de interpretaciones de piano

Autor: Margarita López Ramos

Tutor: Dr. José Luis Blanco Murillo

Departamento: Señales, Sistemas y Radiocomunicaciones

MIEMBROS DEL TRIBUNAL

Presidente: D. ……

Vocal: D. ……..

Secretario: D. ……..

Suplente: D. ……..

Los miembros del tribunal arriba nombrados acuerdan otorgar la calificación de: ……

Madrid, a de de 20…

UNIVERSIDAD POLITÉCNICA DE MADRID

ESCUELA TÉCNICA SUPERIOR DE INGENIEROS DE TELECOMUNICACIÓN

GRADO EN INGENIERÍA DE TECNOLOGÍAS Y SERVICIOS DE TELECOMUNICACIÓN

TRABAJO FIN DE GRADO

Desarrollo y evaluación de un sistema de identificación de notas a partir de interpretaciones de piano

MARGARITA LÓPEZ RAMOS

2024

RESUMEN

En el ámbito de la música computacional, la clasificación y detección precisa de notas y acordes en interpretaciones representa un reto significativo debido a la complejidad inherente de las ejecuciones polifónicas, la variabilidad debida al intérprete, y la variedad de instrumentos implicados. La convergencia de técnicas avanzadas de procesamiento de señales y aprendizaje profundo ha allanado el camino para el desarrollo de sistemas de clasificación y detección, lo que nos permite evaluar y comparar el resultado que se obtiene con distintas técnicas. Esto resulta útil no sólo para tener una reconstrucción de la composición, sino también para ayudar a los intérpretes noveles a mejorar sus interpretaciones de forma automática, la detección y clasificación de matices expresivos en la dinámica o el timbre, entre otros.

En el pasado, este tipo de sistemas se centraban en técnicas de detección basadas en la estructura de las señales, el funcionamiento del piano y sus propiedades. A día de hoy, la mayoría de estos sistemas emplean modelos de inteligencia artificial entrenados con extensas bases de datos, permitiendo la identificación y etiquetado de notas individuales con una precisión sin precedentes. Sin embargo, resulta mucho más interesante considerar esquemas no supervisados, que eviten la necesidad de disponer de etiquetas centrándose en interpretaciones reales, para luego buscar el mejor ajuste de las notas interpretadas. Y es que la aplicación de algoritmos de procesamiento de señales optimizados para la naturaleza específica del piano permite operar en tiempo real, esencial para aplicaciones interactivas; tanto para las técnicas más convencionales como las más novedosas.

El trabajo explora las características fundamentales, metodologías y potenciales aplicaciones de estos sistemas. Se han desarrollado distintas versiones del sistema, partiendo de las técnicas tradicionales, hasta llegar a los modelos computacionales más avanzados, centrándose en todo momento en el sonido de piano. El sistema desarrollado y evaluado aborda cuatro aproximaciones distintas: la extracción de frecuencia dominante, un modelo discriminante SVM, un modelo generativo GMM y una red LSTM. Para el entrenamiento de los modelos de aprendizaje automático, se han utilizado representaciones de audio como los coeficientes cepstrales en frecuencia Mel (MFCC), conocidos por su capacidad para capturar las características más relevantes del espectro de audio y mejorar la capacidad predictiva de los modelos.

La evaluación de los resultados se ha desarrollado sobre bases de datos controladas, comparando la efectividad de las distintas técnicas según distintos criterios y dimensiones.

Se concluye que el proyecto ha alcanzado estándares significativos de calidad en la precisión y eficiencia de la identificación de notas en interpretaciones de piano. Los resultados obtenidos validan la efectividad de integrar los enfoques utilizados de aprendizaje automático para abordar este desafío técnico. Para futuros trabajos, se recomienda continuar refinando los modelos existentes y explorar nuevas técnicas para optimizar aún más el rendimiento del sistema en diferentes contextos musicales y condiciones acústicas.

PALABRAS CLAVE

Piano, detección de actividad, identificación y transcripción de notas, procesado de señal, aprendizaje automático.

SUMMARY

In the field of computational music, the accurate classification and detection of notes and chords in performances pose a significant challenge due to the inherent complexity of polyphonic executions, variability introduced by performers, and the diversity of instruments involved. The convergence of advanced signal processing techniques and deep learning has paved the way for developing classification and detection systems, enabling us to evaluate and compare outcomes obtained using different techniques. This is valuable for reconstructing compositions and aiding novice performers in automatically improving their interpretations and detecting and classifying expressive nuances in dynamics or timbre, among others.

Previously, such systems focused on detection techniques based on signal structures, piano mechanics, and their properties. Nowadays, most of these systems employ artificial intelligence models trained on extensive databases, allowing for the identification and labeling of individual notes with unprecedented accuracy. However, it is also intriguing to consider unsupervised schemes that avoid the need for labels by focusing on real interpretations.

Signal processing algorithms optimized for the piano's specific nature enable real-time operation, which is crucial for interactive applications encompassing both conventional and cutting-edge techniques. The work explores these systems' fundamental characteristics, methodologies, and potential applications. Various versions of the system have been developed, starting from traditional techniques and progressing to more advanced computational models, with a constant focus on piano sound.

This project has designed, implemented, and tested a system for identifying musical notes using four distinct models: dominant frequency extraction, discriminant SVM, generative GMM, and LSTM nets. For training machine learning models, audio features such as Mel-frequency cepstral coefficients (MFCCs) have been utilized, known for their ability to capture the most relevant characteristics of the audio spectrum and improve predictive model capabilities.

Results were evaluated on controlled databases, comparing the effectiveness of different techniques across various criteria and dimensions (precision, robustness, speed, etc.).

The project concludes that significant quality standards have been achieved in the accuracy and efficiency of identifying notes in piano performances. The results validate the effectiveness of integrating the machine learning approaches to tackle this technical challenge. For future research, it is recommended to continue refining existing models and exploring new techniques to optimize system performance across different musical contexts and acoustic conditions.

KEYWORDS

Piano, activity detection, note identification and transcription, signal processing, machine learning.

AGRADECIMIENTOS

Quiero expresar mi más profundo agradecimiento a mis padres por su confianza inquebrantable en mí. Su constante apoyo y aliento me han impulsado a alcanzar este logro académico. Gracias por creer en mí incluso cuando yo dudaba de mis propias capacidades.

A mi hermano, por su constante ánimo y comprensión durante este proceso. Su apoyo moral ha significado mucho para mí y ha sido un gran incentivo para seguir adelante.

También quiero agradecer a mis amigas por su amistad, comprensión y apoyo incondicional. Sus ánimos y momentos compartidos han sido un gran sostén durante los momentos difíciles y han enriquecido mi experiencia académica. Gracias por la confianza, honestidad, amabilidad, vitalidad, ayuda, lealtad, intensidad, transparencia, alegría y solidaridad, que siempre demostraron.

Por último, pero no menos importante, quiero agradecer a mi tutor, José Luis Blanco Murillo por su guía experta, dedicación y apoyo continuo a lo largo de la elaboración de este trabajo. Sus conocimientos y orientación han sido cruciales para alcanzar los objetivos planteados.

Este proyecto no solo representa mi esfuerzo individual, sino también el respaldo y la contribución invaluable de mis seres queridos. Gracias a todos por estar siempre ahí para mí.

INDICE

1. INTRODUCCIÓN Y OBJETIVOS 1
1.1. Introducción 1
1.1.1. Contexto 1
1.1.2 Motivación del trabajo 3
1.2. Objetivos 4
1.3. Metodología 4
1.4. Tareas 5
1.5. Requisitos 6
2. ESTADO DEL ARTE 7
2.1. Técnicas tradicionales de clasificación 7
2.1.1. Extracción de la frecuencia dominante 7
2.2 Coeficientes cepstrales (MFCC) 9
2.1.2. Extracción de mfcc 9
2.3 Modelos discriminantes 10
2.2.1 SVM 10
2.4. Modelos generativos 13
2.4.1. GMM 13
2.5. Modelos basados en aprendizaje profundo 15
2.5.1. LSTM 15
2.6. Resumen de los modelos disponibles 16
3. DESARROLLO 18
3.1. Preparación de los conjuntos de datos 18
3.1.1. Materiales 18
3.1.2. Tareas de preprocesamiento de datos 19
3.1.3. Extracción de caracteristicas para EL aprendizaje 22
3.2. Modelo basado en la frecuencia dominante 23
3.2.1. Formulación del sistema propuesto 23
3.2.2. Pruebas desarrolladas 25
3.3. Desarrollo del clasificador discriminante 26
3.3.1. Formulación del sistema propuesto 26
3.4. Desarrollo del modelo basado en técnicas generativas clásicas (GMM) 29
3.4.1. Formulación del sistema propuesto 29
3.5. Desarrollo del modelo basado en técnicas generativas profundas (LSTM) 31
3.5.1. Formulación del sistema propuesto 31
3.6. Pruebas para las maquinas de aprendizaje 33
4. RESULTADOS Y DISCUSIÓN 35
4.1. Resultados Extracción frecuencia dominate 35

4.2. Resultados clasificador SVM 38
4.3. Resultados del clasificador GMM 40
4.4. Resultados del clasificador LSTM 42
4.5. Resumen de resultados de los diferentes métodos 44
5. CONCLUSIONES Y LÍNEAS FUTURAS 46
5.1. Conclusiones 46
5.1.1. Limitaciones 46
5.1.1. Conclusiones Específicas 47
5.2. Lineas futuras 47
6. BIBLIOGRAFÍA 49
ANEXO A: ASPECTOS ÉTICOS, ECONÓMICOS, SOCIALES Y AMBIENTALES 50
A.1 Introducción 50
A.2 Descripción de impactos relevantes relacionados con el proyecto 50
A.3 Análisis detallado de alguno de los principales impactos 51
A.4 Conclusiones 52
ANEXO B: PRESUPUESTO ECONÓMICO 53

INDICE DE FIGURAS

Figura 1. El mecanismo de producción de sonido. Tomado de [1] en abril..... 1

Figura 2. Tabla frecuencias notas musicales. Tomado de [4] en febrero 2024..... 2

Figura 3. Metodología utilizada para el desarrollo del sistema. Tomado de [7] en Mayo..... 5

Figura 4. Forma de onda (izquierda) y contenido espectral (derecha) de una muestra de la nota LA4 con la frecuencia dominante marcada en el espectro. Elaboración propia. Tomada en octubre..... 8

Figura 5. Contenido espectral de un registro de la nota Do4. Aparecen marcadas la frecuencia fundamental y la frecuencia dominante. Elaboración propia..... 8

Figura 6. Diagrama de extracción de MFCC. Tomada de [9] en Mayo..... 9

Figura 7. Gráfica función de Kernel, se puede observar una representación 2D y 3D, al aplicar Kernel, de la distribución de puntos. Tomada de [11] en noviembre, ... 11

Figura 8. Clasificador SVM lineal separando las dos clases. Tomada de [12] en noviembre. 11

Figura 9. Representación gráfica de los cambios que provoca al hiperplano la alteración del parámetro C. Tomada de [13] en noviembre..... 12

Figura 10. Diagrama de bloques GMM. Tomado de [16] en diciembre..... 13

Figura 11. Diagramas de dispersión dependiendo de la configuración de los clusters. Tomada de [17] en enero..... 14

Figura 12. Diagrama de una red LSTM para clasificación. Tomada de [18] en mayo. 16

Figura 13. Diagrama de una red neuronal de LSTM para regresión. Tomada de [18] en mayo..... 16

Figura 14. Tabla comparativa de los distintos modelos. Elaboración propia. 17

Figura 15. Tabla resumen de los materiales empleados en el desarrollo y el entrenamiento. 19

Figura 16. Forma normalizada, la amplitud no sobrepasa el rango de [-1,1]. Elaboración propia. 20

Figura 17. Espectrograma melodía de prueba. Elaboración propia. 21

Figura 18. Energía localizada, marcados con triángulos verdes los puntos de los ataques a una nota. Elaboración propia..... 21

Figura 19. Representación gráfica de los MFCC tras la eliminación de los 2 primeros coeficientes, Elaboración propia..... 22

Figura 20. Diagrama de bloques empleado para la clasificación de registros según la nota dominante. Elaboración propia..... 23

Figura 21. Curva exponencial de las notas musicales..... 24

Figura 22. Diagrama de barras que representa la media de los márgenes de error calculados por octava. Elaboración propia..... 24

Figura 23. Contenido espectral que representa el acorde de Lam (La, Do, Mi), con sus respectivas frecuencias marcadas. Elaboración propia. 25

Figura 24. Diagrama de bloques del modelo de SVM. Elaboración propia. 27

Figura 25. Proyección PCA de los datos de entrenamiento del SVM. Elaboración propia. 28

Figura 26. Diagrama de bloques modelo GMM. Elaboración propia. Tomada en mayo. 29

Figura 27. Gráfica de dispersión de la mezcla gaussiana por nota. Elaboración propia. 30

Figura 28. Diagrama de bloques para el entrenamiento de LSTM. Elaboración propia. 31

Figura 29. Diagrama que incluye todas las capas que se aplican en este LSTM. Tomada de en junio. 32

Figura 30. Ejemplo de error, se observa como la frecuencia dominante no coincide con la que realmente corresponde a un Re3. Elaboración propia. Tomada en octubre. 36

Figura 31. Tasa de aciertos de la identificación de notas por frecuencia dominante por octava. Elaboración propia. Tomada en mayo. 37

Figura 32. Tabla de Tasa de Aciertos del SVM, siendo el eje X los diferentes valores de solapamiento y el eje Y los diferentes tamaños de ventanas para los que se ha analizado el modelo. Elaboración propia. 39

Figura 33. Tabla de Tasa de Aciertos del GMM para 3 archivos de audio por clase, siendo el eje X los diferentes valores de solapamiento y el eje Y los diferentes tamaños de ventanas para los que se ha analizado el modelo. Elaboración propia. 41

Figura 34. Tabla de Tasa de Aciertos del GMM para 10 archivos de audio por clase, siendo el eje X los diferentes valores de solapamiento y el eje Y los diferentes tamaños de ventanas para los que se ha analizado el modelo. Elaboración propia. Tomada en junio. 42

Figura 35. Tabla de Tasa de Aciertos del LSTM para 10 archivos de audio por clase, siendo el eje X los diferentes valores de solapamiento y el eje Y los diferentes tamaños de ventanas para los que se ha analizado el modelo. Elaboración propia. 43

LISTA DE ACRÓNIMOS

FFT - Transformada Rápida de Fourier (Fast Fourier Transform)

MFCC - Coeficientes Cepstrales de Frecuencia Melódica (Mel-Frequency Cepstral Coefficients)

SVM - Máquina de Vectores de Soporte (Support Vector Machine)

GMM - Modelo de Mezclas Gaussianas (Gaussian Mixture Model)

PCA - Análisis de Componentes Principales (Principal Component Analysis)

RBF - Función de Base Radial (Radial Basis Function)

LSTM - Memoria a Corto-Largo Plazo (Long Short-Term Memory)

1. INTRODUCCIÓN Y OBJETIVOS

1.1. INTRODUCCIÓN

En este capítulo, se abordará en profundidad el funcionamiento del piano, explorando detalladamente sus mecanismos de producción sonora. Se analizará cómo la interacción entre los martillos, las cuerdas, los amortiguadores, los puentes y la caja de resonancia da lugar a la amplia gama de sonidos que caracterizan a este instrumento. Todos estos aspectos condicionan nuestra capacidad para detectar e identificar las notas en una interpretación a piano.

1.1.1. CONTEXTO

El piano es un instrumento musical único debido a su método de producción de sonido Combina la percusión de cuerdas con la resonancia de la caja. Cuando se presiona una o más teclas del piano, un martillo golpea las cuerdas conectadas a dichas teclas [1] Este golpe origina una vibración en las cuerdas, produciendo así un sonido suave de la nota. Debido a la presencia de un amortiguador "*damper*" [2] que se muestra a la derecha de la Figura 1, se ralentiza el movimiento del martillo controlando así su velocidad y evitando que el golpe produzca un sonido abrupto. Uno de los extremos de las cuerdas está sujeto a las clavijas de afinación las cuales permiten ajustar su tensión para controlar la afinación. El otro extremo de las cuerdas se apoya en los puentes, que están unidos a una caja.

A través de estos puentes, las vibraciones de las cuerdas se transmiten a la caja de resonancia, según se muestra a la izquierda de la Figura 1. Con todo, el piano logra producir un sonido más fuerte y amplificado. Esta forma de producir sonidos se refleja en la estructura temporal y frecuencial de los registros sonoros.

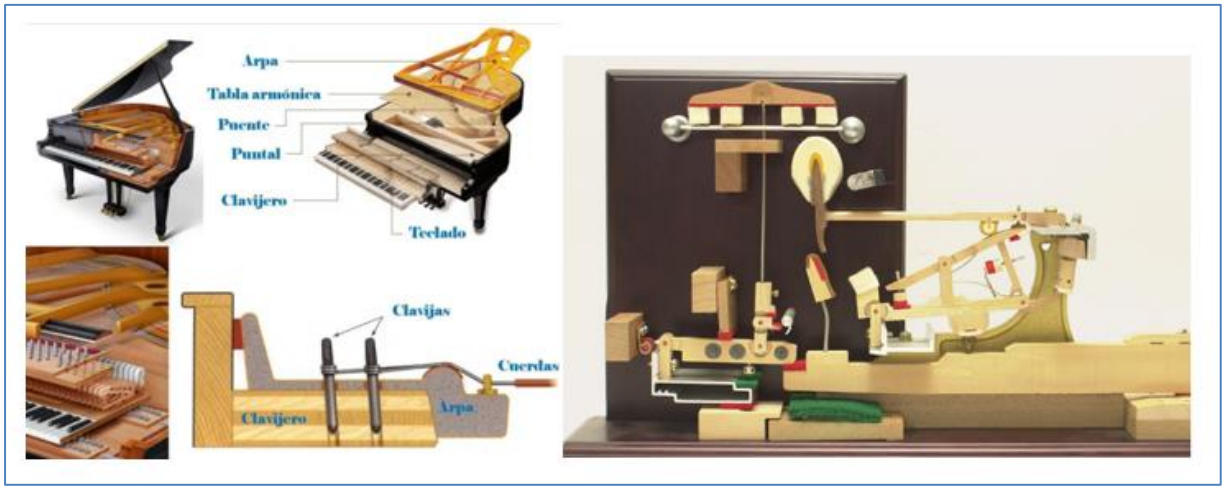

Figura 1. El mecanismo de producción de sonido. Tomado de [1] en abril.

El piano original contaba con 54 teclas. Debido a las exigencias de compositores este número se ve incrementado hoy en día a un estándar de 88 teclas (52 blancas y 36 negras) [3], divididas en 9 octavas.

Siguiendo esta secuencia, cuando se presiona una tecla, activas un mecanismo que produce un sonido. A cada uno de estos sonidos, producido por una tecla diferente, se le asocia un tono. El tono se refiere a la altura percibida del sonido, determinada por la frecuencia de la onda sonora. Los sonidos más agudos se relacionan con los tonos y frecuencias altas y los graves con los tonos y frecuencias bajas. Estos tonos se distribuyen de forma organizada a lo largo de las teclas del piano conforme a una escala.

FRECUENCIA DE LAS NOTAS MUSICALES EN HERCIOS (Hz)									
	OCTAVA 0	OCTAVA 1	OCTAVA 2	OCTAVA 3	OCTAVA 4	OCTAVA 5	OCTAVA 6	OCTAVA 7	OCTAVA 8
Do	16,3516	32,7032	65,4064	130,813	261,626	523,251	1046,50	2093,00	4186,01
Do# / Reb	17,3239	34,6479	69,2957	138,591	277,183	554,365	1108,73	2217,46	4434.92
Re	18,3540	36,7081	73,4162	146,832	293,665	587,330	1174,66	2349,32	4698,64
Re# / Mib	19,4454	38,8909	77,7817	155,563	311,127	622,254	1244,51	2489,02	4978,04
Mi	20,6017	41,2035	82,4069	164,814	329,628	659,255	1318,51	2637,02	5274,04
Fa	21,8268	43,6536	87,3071	174,614	349,228	698,456	1396,91	2793,83	5587,66
Fa# / Solb	23,1246	46,2493	92,4986	184,997	369,994	739,989	1479,98	2959,96	5919,92
Sol	24,4997	48,9995	97,9989	195,998	391,995	783,991	1567,98	3135,96	6271,92
Sol# / Lab	25,9565	51,9130	103,826	207,652	415,305	830,609	1661,22	3322,44	6644,88
La	27,5000	55,0000	110,000	220,000	440,000	880,000	1760,00	3520,00	7040,00
La# / Sib	29,1353	58,2705	116,541	233,082	466,164	932,328	1864,66	3729,31	7458,62
Si	30,8677	61,7354	123,471	246,942	493,883	987,767	1975,53	3951,07	7902,14

OCTAVA 1 OCTAVA 2 OCTAVA 3 OCTAVA 4 OCTAVA 5 OCTAVA 6 OCTAVA 7

Figura 2. Tabla frecuencias notas musicales. Tomado de [4] en febrero 2024.

Para simplificar el estudio y ejecución de la música se les ha dado nombre a determinadas frecuencias y son las que llamamos “notas musicales”. Una nota musical es un nombre dado a determinada frecuencia de sonido y a la frecuencia que vibra al doble de velocidad de ese tono. Dentro de nuestro rango de audición, se podría producir una cantidad infinita de notas. Por ejemplo, un nombre para 10 Hz, otros nombres para 10.1 Hz, 10.2 Hz, etc. Las décimas serían infinitas. Sin embargo, al tratar de construir instrumentos que produjeran sonidos armoniosos, era necesario organizar las frecuencias y crear un estándar que todos los instrumentos pudieran seguir, un método de notación. Los nombres, arreglos y frecuencias de las notas han variado a lo largo de la historia hasta converger en varios estándares utilizados hoy en día [5].

Los dos sistemas de notación musical más comunes son el sistema de notación occidental (DO, RE, MI, FA, SOL, LA, SI), que incluye la notación estándar utilizada en partituras de música clásica y popular en Europa y América del Norte, y el sistema de notación de cifrado (C, D,E,F,G,B,A), que se utiliza en estilos como el jazz, el pop y la música folclórica. La frecuencia que va de un punto hasta su doble se divide en 12 partes o 12 notas. De las 12 notas, 7 tienen nombres únicos: do, re, mi, fa, sol, la y si (las notas blancas del piano), mientras que las otras 5 notas llevan el nombre de las notas que vienen antes o después de ellas. Por ejemplo, la nota entre Do y Re podría llamarse Do sostenido (DO#) o Re bemol (REb). En una partitura, el "Sostenido" está encima de la nota y el "Bemol" está debajo de la nota.

La estructura anterior hace que las frecuencias asociadas al piano sigan una progresión exponencial. Cada salto de semitono se describe como una multiplicación de la frecuencia por la raíz duodécima de 2. La relación básica que guardan las frecuencias con el mismo nombre de notas de octavas sucesivas es aproximadamente el doble de la frecuencia. Como ejemplo puede servir el La Central (LA4) cuya frecuencia es 440Hz. Por lo tanto, la frecuencia del La anterior (LA3) sería de 220Hz y el la del La posterior (LA5) debe ser de 880Hz. Todo esto se comprueba en los valores de frecuencia que se asocian a las notas del piano en la Figura 2. Las frecuencias se distribuyen según el patrón indicado a lo largo de siete octavas (parte inferior de la Figura 2) y doce notas por octava (ver Tabla en la misma Figura).

1.1.2 MOTIVACIÓN DEL TRABAJO

El piano es un instrumento fundamental en la formación musical y la composición debido a su versatilidad, rango tonal amplio y capacidad para expresar una amplia gama de emociones. Su uso extendido lo convierte en una plataforma ideal para el desarrollo de sistemas de detección de notas.

La detección de notas en piano es un campo de estudio con un gran interés y relevancia por diversas razones. A continuación, se presentan algunos ejemplos específicos de sus posibles aplicaciones:

1. Extracción de partituras a partir de interpretaciones: Imagine un software que pueda transcribir automáticamente una pieza que usted toca al piano en una partitura digital. Esto sería invaluable para músicos, compositores y educadores. Como ejemplo, la empresa Zenph Sound Innovations ha desarrollado tecnología para transcribir interpretaciones de piano grabadas históricamente en partituras digitales precisas. Por ejemplo, reconstruyeron digitalmente la interpretación de Glenn Gould de las Variaciones Goldberg de Bach, convirtiéndola en una partitura digital fiel.

2. Evaluación de interpretaciones en tiempo real: Un sistema de detección de notas podría usarse para evaluar la precisión de las interpretaciones de los estudiantes de piano, proporcionándoles retroalimentación inmediata sobre su ejecución. Un ejemplo bastante notorio es el software "SmartMusic" de MakeMusic que proporciona retroalimentación instantánea a estudiantes de música. Utiliza la detección de notas para evaluar la precisión y el ritmo de las interpretaciones de los estudiantes de piano mientras tocan, ofreciendo sugerencias y puntuaciones en tiempo real.

3. Entrenamiento y formación de intérpretes: Un sistema de este tipo podría ser utilizado por los pianistas para practicar y mejorar su técnica, identificando áreas que necesitan trabajo y proporcionando ejercicios personalizados. En la actualidad un sistema llamado "Piano Marvel" utiliza tecnología de detección de notas para ayudar a los pianistas a practicar de manera efectiva. Identifica áreas de mejora técnica y ofrece ejercicios personalizados basados en el rendimiento del estudiante, adaptándose a su progreso.

4. Apoyo al proceso de composición: Un compositor podría usar un sistema de detección de notas para experimentar con diferentes ideas melódicas y armónicas, improvisando al piano. El compositor y pianista David Cope sirve como ejemplo para esta aplicación ya que ha utilizado sistemas de inteligencia artificial para explorar y generar nuevas composiciones musicales. Aunque no específicamente para detección de notas en tiempo real, demuestra cómo la tecnología puede ser utilizada creativamente en el proceso de composición musical.

Estas son sólo algunas de las muchas posibilidades que ofrece la detección de notas en piano. A medida que la tecnología continúe desarrollándose, podemos esperar ver aún más aplicaciones innovadoras y creativas en el futuro. Sin embargo, la detección de notas en piano presenta un desafío computacional en la práctica debido a la complejidad del sonido del piano, las condiciones de la interpretación y de su grabación, así como la variabilidad en la interpretación musical. De esta forma, los factores que elevan la dificultad de la tarea incluyen, entre otros los siguientes:

La presencia de ruido de fondo sin duda puede afectar a la precisión en la detección de las notas. Las previsibles variaciones en la interpretación de una misma nota en aspectos como la velocidad, la fuerza de pulsación utilizada. También, los acordes con múltiples notas simultáneas pueden ser difíciles de separar y analizar individualmente. En el caso de piezas con varias melodías independientes, la detección de cada instrumento requiere técnicas de separación de fuentes.

A pesar de estos desafíos, los avances en técnicas de procesamiento de audio y aprendizaje automático han permitido un progreso significativo en la detección de notas en piano. A lo largo del desarrollo de este trabajo evaluamos y comparamos varios de estos métodos, prestando especial atención al impacto que tienen aspectos como los anteriores.

1.2. OBJETIVOS

El presente Trabajo de Fin de Grado ha sido desarrollado entorno a un único objetivo principal, para cuya consecución se ha definido una serie de objetivos secundarios.

Objetivo principal: Desarrollar y evaluar un sistema automático de detección de notas musicales para piano, utilizando algoritmos de procesamiento de señales optimizados para el sonido de este instrumento y evaluando distintas alternativas para su implementación.

Objetivos secundarios: Para lograr el objetivo principal, y validar su consecución, se establecerán los siguientes objetivos secundarios.

- Recopilar una base de datos de sonidos de pianos con notas etiquetadas que facilite la posterior evaluación de los algoritmos desarrollados y el entrenamiento de los sistemas automáticos.

- Desarrollar y evaluar soluciones basadas en las características de los sonidos de piano y de las grabaciones disponibles.

- Evidenciar los retos y necesidades que plantea la identificación automática de notas de piano.

- Analizar el impacto ético, económico y social tras un sistema de identificación automática de notas. Para ello se toma en especial consideración la necesidad de datos, la propiedad de estos, y las oportunidades que ofrece una herramienta para el desarrollo educativo y social.

1.3. METODOLOGÍA

La metodología seguida a lo largo del trabajo es la llamada Iterativa Incremental. La metodología Iterativa Incremental es un enfoque popular para el desarrollo de software basada en la idea de crear versiones incrementales de un producto a lo largo de ciclos repetitivos. A diferencia del modelo tradicional en cascada, donde todo el proyecto se planifica y ejecuta de una vez, este enfoque se caracteriza por su flexibilidad y adaptación a medida que avanza el desarrollo. [6]

Uno de los fundamentos clave consiste en el desarrollo en etapas. El proyecto se dividió en iteraciones, cada una con un conjunto definido de objetivos y entregables.

El desarrollo del sistema de identificación automática de notas musicales mediante los modelos de extracción de frecuencia dominante, SVM, GMM y LSTM ha seguido rigurosamente la metodología Iterativa Incremental. Este enfoque ha permitido avanzar de manera progresiva y efectiva, asegurando que cada modelo se optimice y ajuste iterativamente hasta alcanzar los niveles de precisión necesarios.

Desde el inicio del proyecto, cada modelo ha comenzado con la creación de un prototipo inicial, seguido de pruebas exhaustivas para evaluar su efectividad en la identificación precisa de notas musicales. Esta fase inicial nos ha proporcionado una base sólida para identificar áreas de mejora y ajuste en cada iteración subsiguiente. Durante cada ciclo de desarrollo, nos hemos centrado en implementar mejoras graduales en los modelos. Esto incluye la refinación de algoritmos, ajuste de parámetros y la incorporación de nuevas técnicas conforme se han ido probando y validando los resultados obtenidos en pruebas reales.

La evaluación continua ha sido fundamental en nuestro enfoque iterativo. Cada iteración ha incluido pruebas rigurosas de rendimiento y precisión, utilizando conjuntos de datos diversos y condiciones variables para garantizar la robustez y generalización de los modelos ante diferentes escenarios musicales y ambientales.

Figura 3. Metodología utilizada para el desarrollo del sistema. Tomado de [7] en mayo.

A medida que avanzábamos en el desarrollo, hemos integrado los resultados de cada iteración para mejorar la efectividad global del sistema. Esto ha implicado no solo corregir errores identificados, sino también adaptar los modelos a nuevos requisitos y desafíos surgidos durante el proceso de implementación.

Este enfoque Iterativo Incremental no solo ha optimizado la eficiencia del desarrollo, sino que también ha asegurado que cada modelo cumpla con los estándares de precisión y rendimiento establecidos. La flexibilidad inherente de esta metodología ha sido clave para responder de manera ágil y efectiva a los cambios y ajustes necesarios, permitiéndonos alcanzar los objetivos del proyecto de manera satisfactoria y dentro de los plazos establecidos.

1.4. TAREAS

De forma más específica, las tareas que se realizarán a lo largo del proyecto han consistido en:

- Explorar las características fundamentales, metodologías y potenciales aplicaciones de los sistemas de detección de notas musicales para piano.
- Analizar las diferentes técnicas de procesamiento de señales existentes para la detección de notas musicales, tanto convencionales como novedosas.
- Evaluar el rendimiento de las diferentes técnicas en cuanto a precisión, robustez, velocidad y otros criterios relevantes.
- Explorar las potenciales aplicaciones de los sistemas de detección de notas musicales en diferentes ámbitos, como la educación musical, la composición y la interpretación musicales.

- Desarrollar distintas versiones del sistema de detección de notas musicales para piano: Implementar un sistema de detección de notas musicales basado en técnicas tradicionales de procesamiento de señales.
- Desarrollar un sistema de detección utilizando modelos computacionales más avanzados, como redes neuronales. Evaluar el rendimiento de las diferentes versiones del sistema en cuanto a precisión, robustez, velocidad y otros criterios relevantes.
- Evaluar el rendimiento del sistema de detección de notas musicales para piano en bases de datos controladas.
- Crear y recopilar bases de datos de sonido de piano con notas musicales conocidas.
- Evaluar el rendimiento del sistema de detección de notas musicales en las bases de datos controladas, comparando la efectividad de las diferentes técnicas según distintos criterios y dimensiones, evaluando las fortalezas y debilidades de las soluciones propuestas.
- Analizar los resultados de la evaluación para identificar las fortalezas y debilidades del sistema, y proponer posibles mejoras futuras.

1.5. REQUISITOS

El desarrollo y la evaluación de un sistema de identificación de notas a partir de interpretaciones de piano debe cumplir con una serie de requisitos técnicos y funcionales que garanticen la precisión y efectividad del sistema.

Los requisitos principales fijados para el proyecto se detallan a continuación:

- El sistema debe identificar y clasificar notas musicales con una precisión superior al 90%.
- La tasa de error debe mantenerse por debajo del 40%, con un objetivo específico de menos del 10% para asegurar la alta calidad y fiabilidad del detector/clasificador.
- El sistema debe ser capaz de manejar múltiples fuentes de sonido simultáneamente sin degradar significativamente la precisión ni el tiempo de respuesta.
- El sistema debe ser capaz de operar eficazmente en entornos ruidosos, aplicando técnicas de filtrado y preprocesamiento para minimizar el impacto del ruido de fondo.
- El sistema debe proporcionar una visualización clara y precisa de las notas detectadas y clasificadas, incluyendo opciones para visualización en tiempo real y análisis posterior.
- Debe ser fácil de mantener y actualizar, permitiendo la implementación de mejoras y la corrección de errores de manera eficiente.

Cumplir con estos requisitos es fundamental para el desarrollo y la evaluación de un sistema de identificación de notas a partir de interpretaciones de piano que no solo sea preciso y confiable, sino también robusto, adaptable y fácil de usar. La atención a estos detalles garantizará que el sistema sea adecuado para una amplia gama de aplicaciones, desde educación musical hasta producción profesional de música.

2. ESTADO DEL ARTE

En el ámbito del desarrollo de detectores de notas musicales, el estado del arte abarca una amplia gama de enfoques que van desde técnicas tradicionales hasta métodos más avanzados basados en aprendizaje automático y procesamiento de señales haciendo uso de la inteligencia artificial.

Una de las técnicas es la detección de frecuencia dominante, que permite identificar las notas principales en una grabación de piano mediante el análisis espectral.

En el ámbito del *machine learning*, se utilizan características como los coeficientes cepstrales (MFCC), que capturan las propiedades espectrales del sonido. Los modelos de aprendizaje supervisado, como las máquinas de soporte vectorial (SVM) y los modelos de mezcla gaussiana (GMM), han sido empleados para clasificar las notas con base en los MFCC. Sin embargo, los enfoques más recientes han adoptado redes neuronales recurrentes de memoria a largo corto plazo (LSTM), que son capaces de manejar secuencias temporales y captar dependencias contextuales en la música, mejorando significativamente la precisión del reconocimiento. Estos avances han permitido no solo una mayor exactitud en la identificación de notas individuales, sino también en la transcripción de piezas musicales completas, impulsando aplicaciones prácticas en software educativo como *Yousician* y herramientas de composición asistida por IA como por ejemplo el software AIVA.

En el siguiente capitulo se explicarán detalladamente las técnicas utilizadas en el proyecto para la clasificación de notas musicales, haciendo un recorrido por los aspectos de procesado de señal y aprendizaje automático que dan sentido a las pruebas desarrolladas.

2.1. TÉCNICAS TRADICIONALES DE CLASIFICACIÓN

Entre los elementos más importantes se encuentran las técnicas tradicionales de clasificación que se basan en modelos de señales y extracción de características. Estas técnicas para la clasificación de las notas musicales suelen involucrar el análisis de la señal de audio y la identificación (y extracción) de características relevantes, como la frecuencia dominante, la distribución de los niveles de energía, o representaciones más generales como los coeficientes cepstrales. En este contexto, la estructura de este capítulo comenzará explorando el modelo básico de la señal de audio de notas musicales y discutiendo las diversas técnicas de extracción de características utilizadas.

2.1.1. EXTRACCIÓN DE LA FRECUENCIA DOMINANTE

Cuando se habla de frecuencia dominante se hace referencia a la frecuencia cuya amplitud es más prominente en una señal. En el caso de una señal de audio de una sola tecla pulsada, esa frecuencia es la que determina la nota musical tocada.

La frecuencia dominante puede determinarse mediante el análisis espectral. En nuestro caso, podemos analizarla a través de la descomposición de Fourier, que descompone una señal en sus componentes de frecuencia. La Figura 3 muestra las gráficas de la forma de onda de la señal producida (izquierda) y de su contenido en frecuencia (derecha) de la nota LA4, cuya frecuencia dominante es, en este ejemplo, de 440Hz. Tanto en la forma de onda como en la forma espectral, se observa una modulación en amplitud y fase que se deriva de la estructura del sonido, y que es característica del instrumento. De igual modo, la respuesta en frecuencia del sistema de grabación también se imprime en la señal.

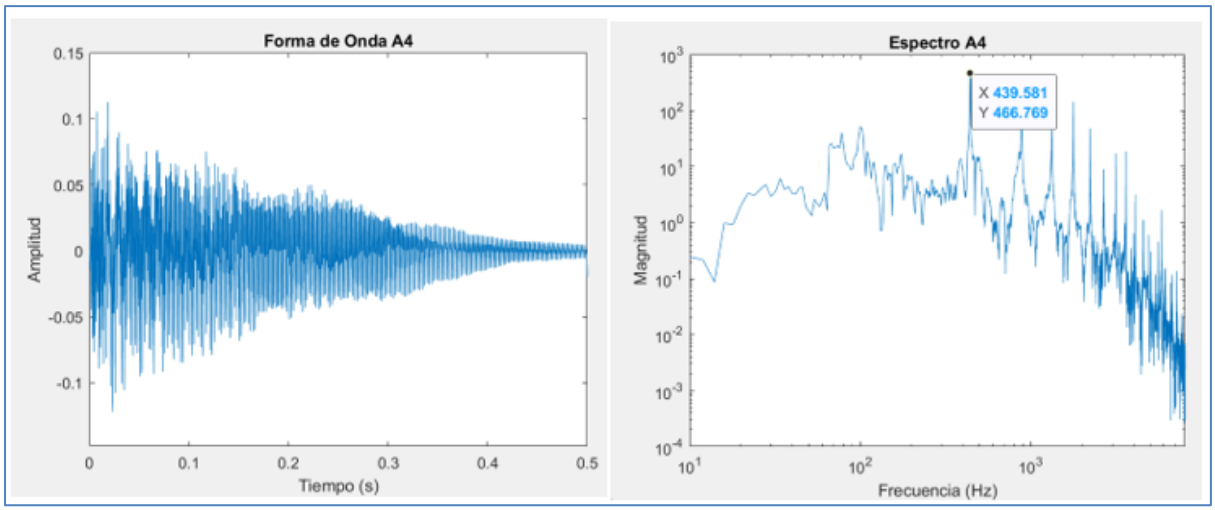

Figura 4. Forma de onda (izquierda) y contenido espectral (derecha) de una muestra de la nota LA4 con la frecuencia dominante marcada en el espectro. Elaboración propia. Tomada en octubre.

A la vista de estas formas, la primera opción para identificar la nota musical tocada en un piano es calcular la frecuencia dominante del sonido registrado, y conectar esta con la nota esperada a esa frecuencia según las escalas del teclado.

A su vez la frecuencia fundamental viene determinada por la altura tonal de una nota, lo que nos permite distinguir un Do de un Re, por ejemplo. Es la frecuencia más grave captada, se identifica como el primer armónico del espectro y a diferencia de la frecuencia dominante no siempre tiene la mayor amplitud.

En general, se puede asumir que la frecuencia fundamental puede determinar únicamente la nota y la frecuencia dominante puede determinar exactamente la nota y la octava en la que se encuentra.

La Figura 5 muestra el espectro de DO4, señalando la frecuencia fundamental (derecha) y la frecuencia dominante (izquierda). Se aprecia con claridad la diferencia entre ambas, permitiéndonos verificar las diferencias espectrales entre el registro de esta nota y el anterior, correspondiente a LA4.

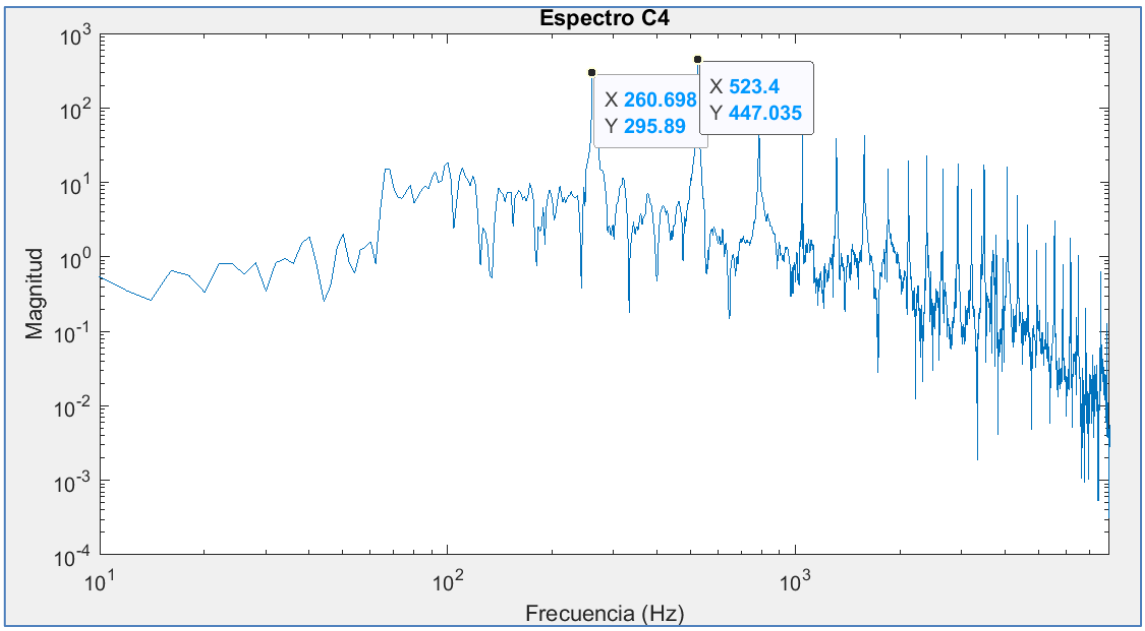

Figura 5. Contenido espectral de un registro de la nota Do4. Aparecen marcadas la frecuencia fundamental y la frecuencia dominante. Elaboración propia.

2.2 COEFICIENTES CEPSTRALES (MFCC)

Los Coeficientes Cepstrales de Frecuencias Mel (MFCC) [8] representan una técnica de extracción de características que ha sido ampliamente adoptada en el procesamiento de señales acústicas. Estos coeficientes capturan información relevante de la frecuencia del espectro de una señal de audio, lo que los hace extremadamente efectivos para diversas tareas de reconocimiento de patrones en el dominio del audio. Su aplicación más destacada es en los sistemas de reconocimiento de habla automática (ASR), donde los MFCC han demostrado ser la característica dominante. Además, se utilizan en el reconocimiento de locutores, permitiendo identificar a los hablantes basándose en sus características vocales únicas, y en el reconocimiento de emociones, aunque en este último caso, suelen combinarse con otras características debido a la naturaleza dispersa de la información emocional en el habla.

Más allá de sus aplicaciones tradicionales en el ámbito acústico, los MFCC han encontrado usos innovadores en campos no acústicos. En la medicina, se han empleado para la clasificación de señales de electrocardiograma (ECG) y electroencefalograma (EEG), demostrando su versatilidad en el análisis de datos biomédicos. En la industria, los MFCC se utilizan para la detección de fallos en rodamientos y engranajes, aunque solo un pequeño porcentaje de estudios han explorado esta aplicación, lo que sugiere una oportunidad de investigación aún en crecimiento. Esta expansión hacia nuevas áreas subraya la adaptabilidad de los MFCC y su potencial para abordar problemas complejos.

A pesar de su amplia adopción, el uso de MFCC presenta varios desafíos. Uno de los más significativos es su sensibilidad al ruido ambiental, lo que puede afectar la precisión en escenarios ruidosos. Para mitigar este problema, los MFCC suelen combinarse con otras características que mejoran la robustez del sistema. Además, la mayoría de los trabajos utilizan la forma estándar de los MFCC, pero algunos estudios han ajustado los parámetros de estos coeficientes para mejorar el rendimiento, especialmente en el reconocimiento de locutores, dada la diversidad de los tractos vocales humanos. Otro desafío es la representación temporal de los datos; aunque los MFCC se calculan en segmentos cortos, muchos estudios prefieren una representación global para manejar la diversidad en la duración de las señales.

Los MFCC siguen siendo una herramienta importante en el procesamiento de señales acústicas, con una adopción creciente en áreas no tradicionales como la medicina y la industria. La continua investigación y ajustes en sus parámetros, junto con la integración de técnicas avanzadas de aprendizaje automático, aseguran que los MFCC seguirán siendo relevantes y útiles en una amplia gama de aplicaciones. Aún en trabajos de reciente publicación, se ha comprobado que los coeficientes MFCC disponen de una amplia capacidad de representación, que en muchos sentidos supera a la de modelos avanzados y representaciones profundas. Todo esto sigue haciendo de los MFCC un punto de partida excelente.

2.1.2. EXTRACCIÓN DE MFCC

El proceso de extracción de los Coeficientes Cepstrales de Frecuencia Mel (MFCC) se compone de varias etapas críticas, cada una diseñada para transformar una señal de audio en una representación compacta y útil para el análisis. A continuación, se muestra un diagrama del proceso:

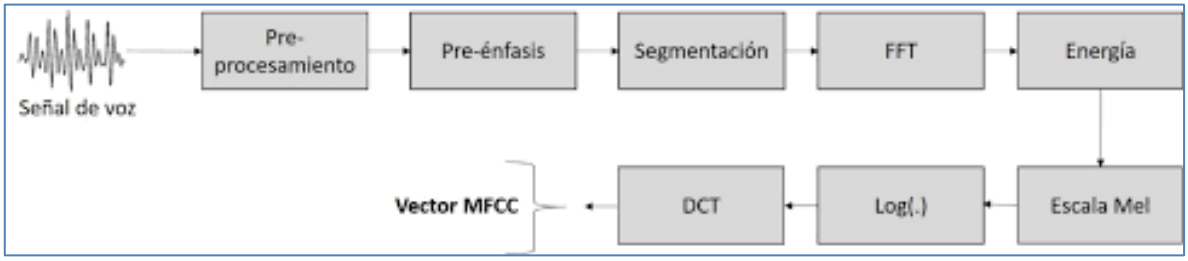

Figura 6. Diagrama de extracción de MFCC. Tomada de [9] en mayo.

Este proceso comienza con el **preénfasis**, una etapa que aplica un filtro a la señal de audio para acentuar las frecuencias altas, compensando la caída de energía en el espectro de estas frecuencias. Esto es importante para preservar la información contenida en las altas frecuencias que puede ser relevante para la identificación y clasificación de señales acústicas.

Posteriormente, la señal preénfatizada se divide en **marcos cortos de tiempo** (*frames*), típicamente de 20 a 40 milisegundos, y hasta 100 ms según la aplicación. Este enmarcado es necesario para capturar las características de la señal que varían con el tiempo. Cada marco se solapa con el anterior, típicamente en un 50%, para asegurar una cobertura continua y para evitar la pérdida de información en las fronteras.

Cada uno de estos marcos se multiplica por una **ventana de Hamming** con el objetivo de minimizar los efectos de borde que podrían distorsionar la Transformada de Fourier. La **Transformada Rápida de Fourier (FFT)** se aplica a cada marco para convertir la señal del dominio temporal al dominio frecuencial, permitiendo el análisis del contenido de frecuencia de la señal.

El siguiente paso implica el uso de un **banco de filtros Mel**, que mapea las magnitudes espectrales obtenidas a la escala Mel, una escala perceptual de frecuencias que simula cómo el oído humano percibe los sonidos. El resultado de esta transformación se logarítmica, comprimiendo el rango dinámico de los valores espectrales.

Finalmente, se aplica la **Transformada Discreta del Coseno (DCT)** a los logaritmos de las magnitudes espectrales en la escala Mel, produciendo los coeficientes cepstrales de frecuencia Mel. Estos coeficientes representan las características de la señal en una forma que es robusta y compacta, adecuada para diversas aplicaciones de procesamiento de señales acústicas y otras áreas.

El resultado es un juego de vectores, cuyos valores depende de diversos parámetros: la duración del marco y su solapamiento, el número de filtros del banco de análisis (FFT), el número de filtros en el banco Mel, o el número de coeficientes cepstrales extraídos. En función de todos ellos, las representaciones obtenidas presentan características similares, pero son intrínsicamente distintas.

2.3 MODELOS DISCRIMINANTES

En el ámbito del aprendizaje automático y la inteligencia artificial, la necesidad de desarrollar modelos precisos y eficientes para la clasificación y el análisis de datos se ha vuelto cada vez más crítica. Diversas técnicas han sido propuestas a lo largo de los años, cada una con sus propias ventajas y limitaciones. Entre estas técnicas, las Máquinas de Soporte Vector, o *Support Vector Machines* (SVM) han ganado importancia a lo largo de los años debido a su sólida base matemática y su capacidad para resolver problemas complejos de manera eficaz. Estas capacidades se han consolidado a lo largo de los años. Y si bien han sido superados por otras técnicas para resolver determinadas aplicaciones, siguen siendo de uso habitual en ciertos ámbitos. A continuación, se presenta un análisis detallado del método SVM, abordando sus fundamentos, requisitos, implementaciones disponibles y métricas de evaluación.

2.2.1 SVM

Las Máquinas de vectores de soporte (SVM) [10] son algoritmos de aprendizaje supervisado ampliamente utilizados en la clasificación y regresión, aplicados en diversas áreas como el procesamiento de señales médicas, procesamiento del lenguaje natural, reconocimiento de imágenes y voz. El objetivo principal de SVM es encontrar un hiperplano óptimo que separe de manera efectiva dos clases diferentes presentes en los datos. Este hiperplano está definido por el margen más amplio posible entre las clases, donde el margen representa la distancia máxima entre el hiperplano y los puntos de datos más cercanos de cada clase.

Los puntos clave de SVM incluyen el concepto de vectores de soporte, que son un subconjunto de las observaciones de entrenamiento que definen la ubicación del hiperplano de separación. SVM está formulado originalmente para problemas de clasificación binaria, aunque se pueden adaptar para problemas multiclase mediante estrategias de uno contra todos o uno contra uno.

Un aspecto distintivo de SVM es su capacidad para manejar eficazmente problemas no lineales a través del uso de funciones *Kernel*. Estas funciones permiten transformar el espacio de características de entrada a un espacio dimensional superior, donde la separación lineal de clases puede ser más sencilla. Ejemplos comunes de funciones *Kernel* incluyen la función de base radial (*radial basis functions*, RBF), lineal, polinómica y sigmoide, cada una adaptada para diferentes tipos de datos y estructuras de separación requeridas.

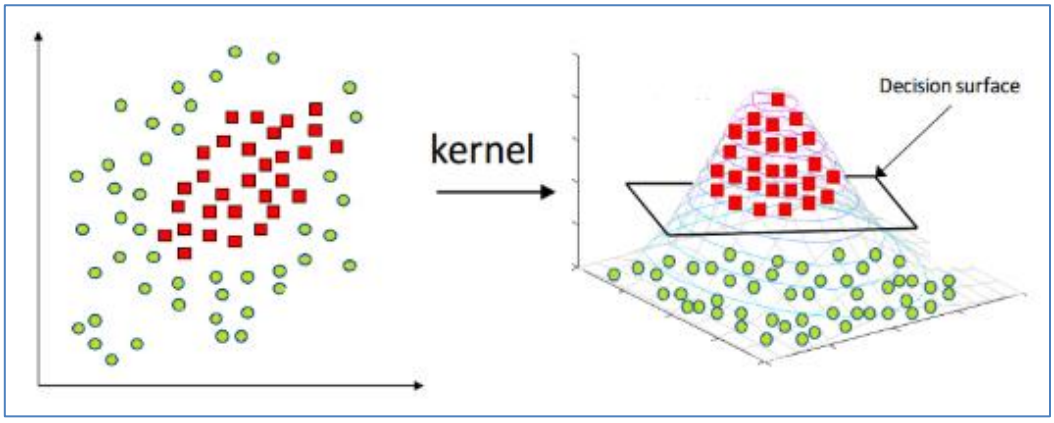

Figura 7. Gráfica función de Kernel, se puede observar una representación 2D y 3D, al aplicar Kernel, de la distribución de puntos. Tomada de [11] en noviembre,

El entrenamiento de los SVM implica resolver un problema de optimización cuadrática para determinar los parámetros del hiperplano de separación, minimizando el margen flexible entre las clases. La eficiencia del modelo radica en que una vez entrenado, solo los vectores de soporte son necesarios para definir la superficie de decisión, lo cual conduce a modelos compactos y eficientes en términos de memoria y de su evaluación.

A continuación, se muestra de forma gráfica el funcionamiento del SVM para vectores de dos dimensiones. En ella se aprecian las dos clases diferenciadas, la existencia de un plano de separación y de dos vectores soporte donde apoya el vector director del plano de separación para poder clasificar correctamente entre las dos clases.

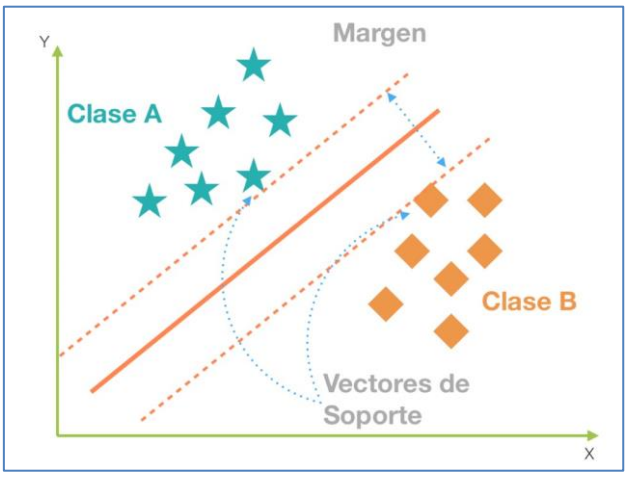

Figura 8. Clasificador SVM lineal separando las dos clases. Tomada de [12] en noviembre.

El parámetro *C* del SVM es importante para el rendimiento del modelo SVM, ya que controla el equilibrio entre la maximización del margen y la minimización del error de clasificación. Un valor alto de *C* trata de clasificar correctamente todos los puntos de datos del conjunto de entrenamiento, pero puede llevar a un sobreajuste, donde el modelo se adapta demasiado a las peculiaridades del conjunto de entrenamiento y no generaliza bien a nuevos datos. Por otro lado, un valor bajo de *C* permite un margen más amplio y tolera algunos errores de clasificación en el conjunto de entrenamiento, lo que puede resultar en un modelo más generalizable. Encontrar el valor óptimo de *C* a menudo requiere experimentación y validación cruzada, evaluando el rendimiento del modelo con diferentes valores de *C* para determinar cuál proporciona el mejor equilibrio entre ajuste y generalización.

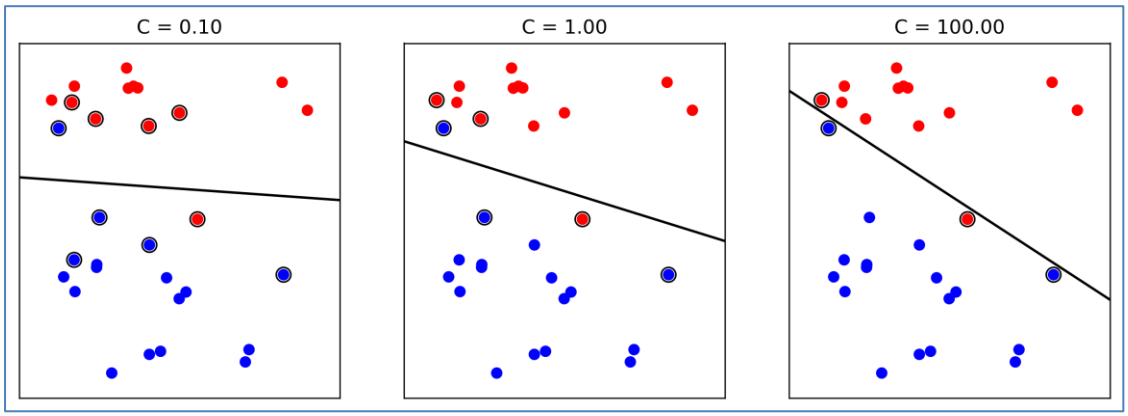

Figura 9. Representación gráfica de los cambios que provoca al hiperplano la alteración del parámetro C. Tomada de [13] en noviembre.

Los modelos de máquinas de vectores de soporte (SVM) han demostrado ser herramientas eficaces en diversas aplicaciones de procesamiento de señales, incluyendo la identificación de notas musicales. En el estudio de *Poliner y Ellis* [14], se presenta un modelo discriminativo para la transcripción polifónica de piano utilizando SVM entrenados en características espectrales. Este enfoque es especialmente relevante para la conexión con los coeficientes cepstrales en frecuencia de Mel (MFCC), que son una representación compacta y robusta de las características espectrales de una señal de audio.

En este estudio, se emplearon SVMs para clasificar instancias de notas a nivel de marco temporal, logrando una precisión de transcripción del 68% en un conjunto de pruebas de nueva generación. Esta efectividad se evaluó mediante la comparación directa con enfoques previos, destacando las ventajas en rendimiento y simplicidad del modelo basado en clasificación sobre los enfoques acústicos tradicionales. Los resultados mostraron que el uso de SVM no solo mejora la precisión, sino que también simplifica el proceso de entrenamiento y clasificación, en comparación con los modelos acústicos basados en conocimiento previo del sonido musical.

En el contexto de la identificación de notas musicales, los MFCC pueden ser utilizados como características de entrada para los modelos SVM, proporcionando una representación robusta y compacta del espectro de audio. La combinación de MFCC y SVM ha demostrado ser eficaz en varias aplicaciones de reconocimiento de patrones de audio, incluida la identificación de notas musicales. Esta combinación permite capturar las variaciones tonales críticas para la identificación precisa de notas, mejorando la robustez del sistema frente a variaciones en las condiciones de grabación.

El estudio de *Poliner y Ellis* también demostró la aplicabilidad y robustez del sistema en diferentes tipos de datos de audio, probándolo tanto en grabaciones de piano reales como sintetizadas. La capacidad del modelo para generalizar entre estas diferentes fuentes de datos refuerza su validez y muestra su potencial para ser utilizado en aplicaciones prácticas. Además, la implementación de SVM con técnicas de optimización como el método de optimización secuencial mínima (SMO) permite manejar grandes volúmenes de datos de manera eficiente, lo que es importante para aplicaciones en tiempo real.

2.4. MODELOS GENERATIVOS

2.4.1. GMM

Los Modelos de Mezcla de Gaussianas (GMM) son ampliamente utilizados en estadística y aprendizaje automático como modelos generativos que capturan distribuciones complejas de datos observados. Un GMM se define como una combinación ponderada de distribuciones gaussianas, cada una caracterizada por su media, matriz de covarianza, y peso de mezcla, que permite aproximar la distribución de probabilidad que subyace a una determinada población.

Su formulación matemática viene dada por

$$p(x|\lambda_i) = \sum_{i=1}^{M} w_i \, g\left(x_t; \mu_j, \Sigma_j\right) \quad \text{donde} \quad \sum_{j=1}^{M} w_j = 1 \tag{1}$$

Donde g $\left(x_t; \mu_j, \Sigma_j\right)$, es la función de densidad de probabilidad de una gaussiana multivariante.

$$g\left(x_t; \mu_j, \Sigma_j\right) = \frac{1}{(2\pi)^{D/2}|\Sigma_j|^{1/2}} \exp\left[-\frac{1}{2}\left(x_t - \mu_j\right)^T \cdot \Sigma_j^{-1} \cdot \left(x_t - \mu_j\right)\right] \tag{2}$$

Donde se identifican con claridad la dimensionalidad del vector, *D*, el vector de medias, μ_j, y la matriz de covarianza correspondiente, $\sum_j$, correspondientes a la *j*-ésima gaussiana de la mezcla.

Existen diversas variantes de GMM [15] que se adaptan según las necesidades y características de los datos. Por ejemplo, las matrices de covarianza pueden ser de rango completo o diagonal, influenciando la capacidad del modelo para capturar correlaciones entre dimensiones de los datos y la complejidad computacional. Además, los parámetros del modelo pueden ser compartidos entre las componentes gaussianas, lo que puede simplificar el modelo o hacerlo más flexible según el contexto de aplicación.

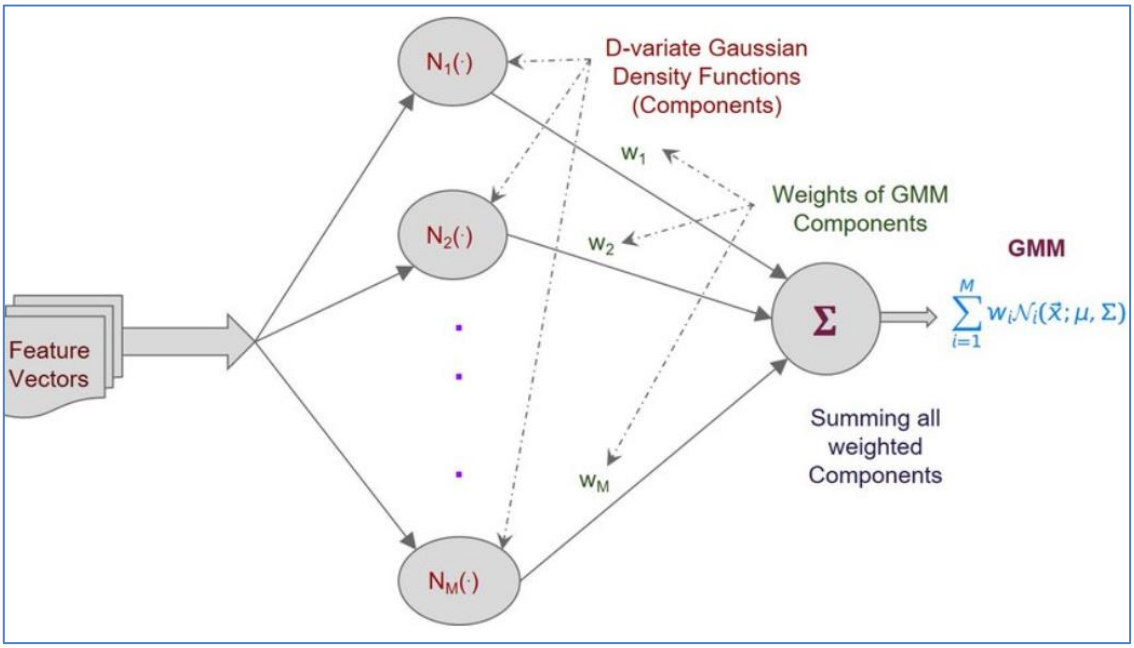

Figura 10. Diagrama de bloques GMM. Tomado de [16] en diciembre.

El algoritmo de Expectación-Maximización (EM) es fundamental para la estimación de los parámetros de un GMM a partir de datos de entrenamiento. Este algoritmo alterna entre el paso de Expectación (E), donde se calculan las probabilidades de pertenencia a cada componente gaussiana, y el paso de Maximización (M), donde se actualizan los parámetros para maximizar la verosimilitud esperada, iterando hasta alcanzar convergencia.

El proceso de ajuste de los GMM utilizando el algoritmo EM se puede visualizar mediante el ajuste progresivo de las agrupaciones (o *clusters*) en los datos.

Los *clusters* son grupos de datos que comparten características similares y son identificados por el modelo. Cada *cluster* es modelado por una distribución gaussiana en el GMM, representando la tendencia central y la dispersión de los datos dentro de ese grupo. El proceso de ajuste de los GMM utilizando el algoritmo EM puede visualizarse mediante la evolución de estos *clusters* en los datos. La siguiente Figura muestra una serie de diagramas de dispersión que ilustran este proceso:

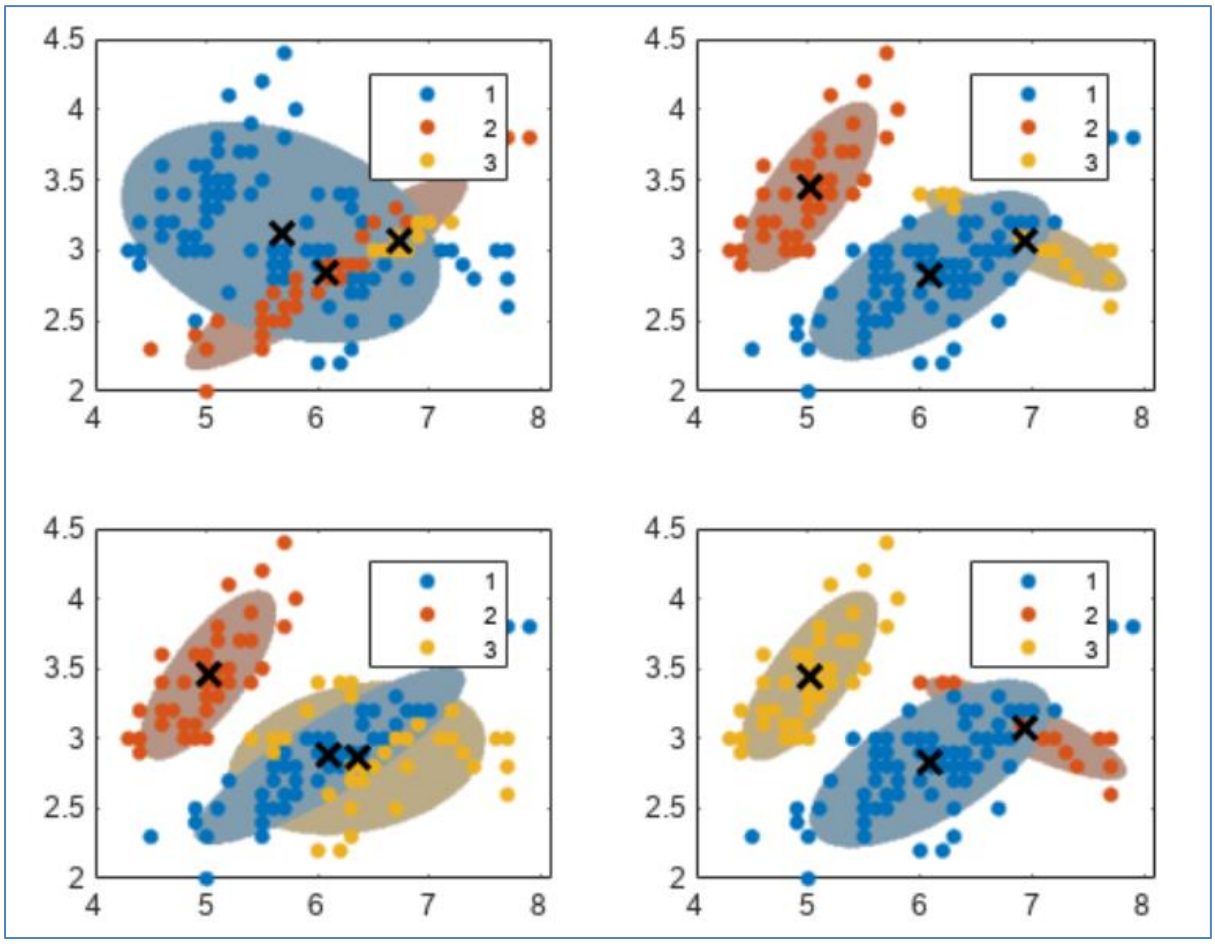

Figura 11. Diagramas de dispersión dependiendo de la configuración de los clusters. Tomada de [17] en enero.

Los GMMs encuentran aplicaciones significativas en sistemas biométricos, como el reconocimiento de voz y el análisis de imágenes. En el reconocimiento de voz, por ejemplo, los GMM modelan características espectrales para identificar patrones en señales de voz, mientras que en el análisis de imágenes se utilizan para la segmentación y el reconocimiento de patrones visuales complejos.

Los GMM representan una herramienta flexible y poderosa para modelar distribuciones de datos complejas, destacándose por su versatilidad en aplicaciones biométricas y su capacidad para adaptarse a diferentes contextos y datos. La continua investigación en métodos de estimación y variantes de GMM asegura que sigan siendo relevantes y efectivos en diversos campos tecnológicos.

De forma más específica en el ámbito de identificación de notas musicales, los GMM se han empleado para modelar la distribución de las características extraídas, como los MFCC, para cada nota musical. Estos modelos capturan la variabilidad intrínseca de la señal de audio de cada nota. Estudios como el de Lee et al. (2018) han comparado los GMM con otros enfoques como Redes Neuronales y Máquinas de Vectores de Soporte (SVM), mostrando que los GMM ofrecen una robustez comparable con una menor complejidad computacional.

Las aplicaciones de MFCC y GMM en el reconocimiento de notas musicales son diversas y abarcan áreas como la transcripción automática de música, la evaluación del rendimiento musical y los sistemas de aprendizaje musical. Por ejemplo, Wang y Zhang (2019) demostraron que los GMM entrenados con características MFCC pueden transcribir con precisión piezas musicales complejas. Kim et al. (2020) utilizaron GMM para evaluar la afinación y el ritmo en interpretaciones musicales, proporcionando retroalimentación detallada a los músicos. Además, García y Soto (2021) desarrollaron una aplicación que utiliza MFCC y GMM para corregir errores en tiempo real durante la práctica musical. Esto último es muy importante, dado que otras técnicas más complejas plantean problemas para su empleo en tiempo real. Por el contrario, el número de operaciones detrás de un esquema MFCC+GMM es relativamente sencillo, toda vez que el modelo GMM ya ha sido entrenado, e incluyendo el tiempo necesario para la parametrización MFCC.

A pesar de los avances, existen desafíos como la mejora de la precisión en entornos ruidosos y la adaptación a diversos estilos musicales. La integración de MFCC y GMM con técnicas de aprendizaje profundo, como Redes Neuronales Convolucionales (CNN) y Redes Neuronales Recurrentes (RNN), promete mejorar aún más la precisión y robustez de los sistemas de reconocimiento de notas musicales. En conclusión, el estado del arte en el uso de MFCC y GMM para el reconocimiento de notas musicales refleja un campo dinámico, con continuas investigaciones que aseguran la relevancia y efectividad de estos métodos en el análisis y procesamiento de señales de audio musical.

2.5. MODELOS BASADOS EN APRENDIZAJE PROFUNDO

2.5.1. LSTM

Las redes neuronales de memoria de corto-largo plazo (LSTM) representan un avance significativo en el tratamiento de datos secuenciales y series temporales en tareas de clasificación y regresión. Estas redes, una variante de las redes neuronales recurrentes (RNN), han demostrado una capacidad notable para aprender y mantener dependencias a largo plazo entre unidades de tiempo en los datos, superando algunas limitaciones inherentes a las RNN estándar, como la incapacidad para gestionar de manera efectiva el problema del desvanecimiento del gradiente.

La arquitectura de una red neuronal de LSTM [18] se compone de varios elementos clave que facilitan el aprendizaje de dependencias temporales. En su forma más básica, una red LSTM incluye una capa de entrada de secuencias y una capa LSTM. La capa de entrada de secuencias es responsable de introducir los datos secuenciales o de series de tiempo en la red. A continuación, la capa LSTM procesa estos datos, aprendiendo las dependencias a largo plazo entre las unidades de tiempo.

En el contexto de la clasificación de secuencias, una red LSTM recibe datos secuenciales a través de su capa de entrada. La capa LSTM procesa estas secuencias, aprendiendo patrones y dependencias a lo largo del tiempo. Finalmente, la capa totalmente conectada y la capa *softmax* generan predicciones de clase basadas en las características extraídas. Un ejemplo clásico de esto es la clasificación de secuencias de texto, donde la red puede aprender el contexto de palabras y frases para asignar etiquetas apropiadas.

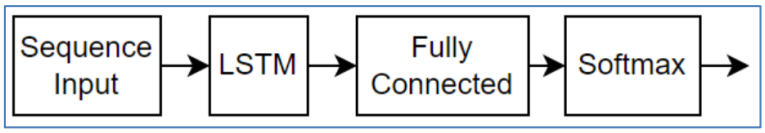

Figura 12. Diagrama de una red LSTM para clasificación. Tomada de [18] en mayo.

En tareas de regresión, la estructura es similar, pero se adapta ligeramente para predecir valores continuos en lugar de categorías discretas. Aquí, después de la capa LSTM, una capa totalmente conectada finaliza la red, produciendo la salida continua necesaria para la tarea de regresión. Un ejemplo típico es la predicción de valores futuros en series temporales financieras, donde la red LSTM puede aprender tendencias y patrones históricos para prever movimientos de precios.

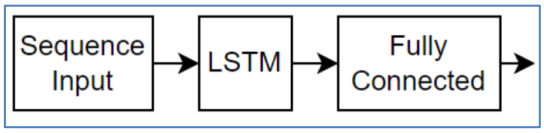

Figura 13. Diagrama de una red neuronal de LSTM para regresión. Tomada de [18] en mayo.

La principal ventaja de las redes LSTM radica en su capacidad para manejar dependencias a largo plazo en los datos secuenciales, lo que las hace particularmente efectivas para tareas donde el contexto histórico es importante. Esto se logra mediante el uso de una estructura de células que pueden retener información durante largos períodos y la incorporación de mecanismos de puerta que controlan el flujo de información dentro y fuera de las células, evitando la pérdida de información relevante.

Las redes neuronales de memoria de corto-largo plazo representan una herramienta poderosa para el análisis de datos secuenciales y series temporales, proporcionando soluciones efectivas tanto para la clasificación como para la regresión. Su capacidad para aprender y retener dependencias a largo plazo las hace indispensables en un amplio rango de aplicaciones, desde el procesamiento del lenguaje natural hasta la predicción financiera.

Las ventajas de utilizar LSTM para la identificación de notas musicales incluyen su capacidad para manejar eficazmente datos secuenciales largos, así como para capturar dependencias a largo plazo, evitando problemas como el desvanecimiento del gradiente. Esto hace que las LSTM sean una herramienta poderosa y efectiva para la clasificación de géneros musicales, facilitando la organización y el acceso mejorado a las bibliotecas de música digitales y potenciando aplicaciones como la recomendación de música personalizada y la clasificación automatizada de nuevas pistas musicales.

Por el contrario, el proceso de aprendizaje de estas redes es costoso, potencialmente lento, y fuertemente dependiente de la red empleada. En otras palabras, requieren de un proceso de ensayo y error, que bien puede acortarse mediante la revisión de casos reportados en la literatura. De cualquier manera, el proceso de entrenamiento es lento e intensivo, como resulta lógico, dado que estas redes se centrar en describir muy bien la dinámica temporal de los datos.

2.6. RESUMEN DE LOS MODELOS DISPONIBLES

En la identificación de notas musicales, existen varios enfoques que varían en precisión, robustez al ruido, facilidad de implementación, eficiencia computacional y adaptabilidad. A continuación, se presenta un resumen de cuatro modelos destacados:

El método de frecuencia dominante es un enfoque simple y eficiente para identificar notas individuales mediante el análisis de la frecuencia principal de una señal de audio. Es fácil de implementar y requiere pocos recursos computacionales. Sin embargo, su precisión disminuye en ambientes ruidosos y en situaciones complejas como la detección de acordes, limitando su adaptabilidad.

La combinación de MFCC (Coeficientes Cepstrales de Frecuencias Melódicas) con SVM (Máquinas de Vectores de Soporte) ofrece una precisión media en la detección de notas. Este enfoque maneja bien características complejas y puede generalizar a diferentes tipos de música, aunque su implementación y eficiencia computacional son moderadas. La robustez al ruido es mejor que en la frecuencia dominante, pero todavía limitada.

Los modelos GMM combinados con los MFCC logran una alta precisión. Son más fáciles de implementar y entrenar en comparación con las SVM, y son eficientes en términos de memoria y procesamiento. La robustez al ruido es similar a la del enfoque del SVM, y su adaptabilidad es bastante alta, siendo adecuados para diversas aplicaciones musicales.

Las LSTM (Memorias a Largo Corto Plazo) son redes neuronales recurrentes que destacan por su capacidad para manejar dependencias temporales y patrones complejos en secuencias de audio. Ofrecen una precisión muy alta y son altamente robustas al ruido, adaptándose bien a diferentes estilos y contextos musicales. Sin embargo, su implementación es compleja y requieren considerable esfuerzo computacional y tiempo de entrenamiento.

A continuación, se muestra una tabla en modo resumen de los criterios de evaluación para cada modelo:

Modelos	Precision	RobustezRuido	FacilidadImplementacion	EficienciaComputacional	Adaptabilidad
Frecuencia Dominante	Alta (solo melodías simples)	Baja	Alta	Alta	Baja
SVM	Media	Media	Media	Media	Media
GMM	Alta	Alta	Alta	Alta	Alta
LSTM	Muy Alta	Alta	Baja	Baja	Muy Alta

Figura 14. Tabla comparativa de los distintos modelos. Elaboración propia.

A la vista de la tabla, tenemos una idea tanto de los resultados que cada una de las aproximaciones debe permitirnos alcanzar, como de las previsibles limitaciones que nos encontraremos. En particular, esperaríamos una mejora progresiva en la exactitud de la identificación de las notas, que es inversamente proporcional a la facilidad de su implementación, su eficiencia computacional, y al grado de dependencia sobre los datos de entrada.

En las siguientes secciones se describen las implementaciones y pruebas realizadas sobre cada una de ellas. Lógicamente, los resultados que se obtienen dependerán en buena medida de los aspectos discutidos anteriormente.

3. DESARROLLO

3.1. PREPARACIÓN DE LOS CONJUNTOS DE DATOS

En la preparación de los conjuntos de datos para el identificador de notas musicales, como se mencionó anteriormente, se ha comenzado haciendo uso de un dispositivo móvil para recopilar una amplia variedad de grabaciones de audios de notas individuales tocadas en un piano real, así como algunas melodías de pruebas en diversos ambientes. Esta diversidad ambiental asegura que los datos capturados reflejen situaciones de la vida real, lo cual es fundamental para obtener resultados realistas en condiciones cotidianas. Este enfoque ayuda a garantizar que el modelo sea robusto y capaz de generalizar adecuadamente.

Cada muestra de audio recopilada ha sido etiquetada cuidadosamente con la nota musical correspondiente. Este etiquetado preciso es esencial para el entrenamiento supervisado del modelo, permitiendo que aprenda a asociar características específicas del sonido con cada nota musical.

3.1.1. MATERIALES

Para las pruebas del identificador de notas musicales, se ha seleccionado un conjunto aleatorio de melodías grabadas también por móvil, con la consideración específica de incluir una diversidad de ruidos ambientales comunes en entornos urbanos, como conversaciones de fondo y el sonido del tráfico. Esta decisión no solo amplía la gama de desafíos acústicos que el detector debe enfrentar, sino que también subraya la importancia de entrenar el modelo en condiciones realistas y variadas. La inclusión deliberada de una amplia variedad de melodías y variaciones de notas garantiza una evaluación exhaustiva de la capacidad del detector en diferentes contextos sonoros.

Además, se ha puesto un énfasis significativo en la diversidad del conjunto de datos no solo en términos de ruido ambiental, sino también en la selección de melodías que abarcan diferentes estilos musicales y rangos tonales. Esto es crucial para validar la robustez del identificador frente a una amplia gama de situaciones de grabación que pueden encontrar los usuarios en la vida real. La combinación de datos suficientemente grande para obtener resultados estadísticamente significativos y lo suficientemente manejable para permitir pruebas eficientes asegura que cada evaluación sea tanto rigurosa como práctica en términos de tiempo y recursos.

Los registros fueron seleccionados de manera aleatoria del conjunto de datos completo, asegurando una muestra imparcial y completamente representativa de la diversidad musical contenida en el corpus. Este proceso meticuloso de selección y el riguroso preprocesamiento de los datos han sido aspectos cruciales para evaluar de manera efectiva el rendimiento del detector de notas musicales desarrollado. Gracias a este subconjunto de datos bien preparado y representativo, hemos podido obtener resultados confiables que no solo validan el funcionamiento actual del modelo, sino que también proporcionan una base sólida para las futuras mejoras y refinamientos del sistema. Este enfoque garantiza que nuestras evaluaciones sean precisas y que nuestras decisiones de desarrollo estén respaldadas por evidencia empírica robusta.

Este proceso preparatorio desempeña un papel fundamental en el desarrollo de un identificador de notas que sea no solo musicalmente preciso, sino también confiable y robusto. La creación de este identificador, único para cada fragmento de registro musical, implica un almacenamiento paralelo estratégico. Esta medida garantiza que su impacto no interfiera prematuramente durante la fase crítica de validación y evaluación de los modelos desarrollados. Es esencial preservar esta separación hasta la verificación del resultado final para asegurar que las métricas obtenidas sean un reflejo fiel de la capacidad predictiva y la calidad general de los modelos implementados.

La siguiente tabla resume los registros empleados en las distintas pruebas realizadas, así como las parametrizaciones del sonido empleadas y sus distintas variantes. Particularmente, se describen las características relativas al origen de los sonidos y a la forma de grabación, así como el número de observaciones por clase y la tipología de las parametrizaciones.

	Datos 1	**Datos 2**	**Datos 3**
Descripción	Notas y acordes independientes sacadas de un sintetizador	Notas y acordes independientes grabadas con el dispositivo móvil	Melodías simples grabadas con el dispositivo móvil
Número de registros	70	70	5
Duración total	3 s	3 s	10-30 s
Número de notas por registro	1 (2-3 si es un acorde)	1 (2-3 si es un acorde)	10-15
Cómo se emplea en las pruebas	Se utilizan para: Comprobar efectividad inicial de los 4 modelos y entrenar a las maquinas.	Se utilizan para: Comprobar efectividad inicial de los 4 modelos y entrenar a las maquinas.	Se segmenta con el método de localización de picos de energía para obtener segmentos con notas individuales para analizar

Figura 15. Tabla resumen de los materiales empleados en el desarrollo y el entrenamiento.

Como se puede apreciar en la tabla, la cantidad de datos disponible es aceptable, pero un poco baja para el entrenamiento de modelos robustos. Si bien habría sido posible extender estos trabajos con conjuntos de datos públicos, se han identificado varias limitaciones en este tipo de conjuntos.

1. Datos sintéticos etiquetados como grabaciones originales, en buena medida debido a que son datos registrados por una fuente externa al generador sintético. Este tipo de situaciones es cada día más habitual, pero es típico que no se describan en la grabación.
2. Múltiples instrumentos o grabaciones generadas sintéticamente a partir de otras originales, por ejemplo, borrando música de fondo. En este caso, los elementos artificiales tienen un alto impacto en los resultados de aprendizaje, sesgando el proceso.

Por todos estos motivos, unidos a las limitaciones para el entrenamiento y adaptación de los modelos, para este trabajo preliminar nos centramos en los conjuntos de datos anteriores, sin ampliar

3.1.2. TAREAS DE PREPROCESAMIENTO DE DATOS

Previo al uso de los registros de audios para el entrenamiento de las máquinas, así como de los archivos de melodías de prueba empleados para evaluar la efectividad de cada método, se llevaron a cabo diversas tareas de preprocesamiento de datos:

NORMALIZACIÓN DE AUDIOS

La primera tarea consistió en cargar los archivos de audio correspondientes a diferentes notas musicales y normalizar las muestras. Esto ha implicado ajustar la amplitud de la señal de audio para que sus valores estén en un rango estándar, típicamente de -1 a 1. La normalización es útil en estos casos para

asegurar que las señales de audio tengan una escala uniforme, lo cual facilita la comparación y el análisis de las características entre diferentes archivos.

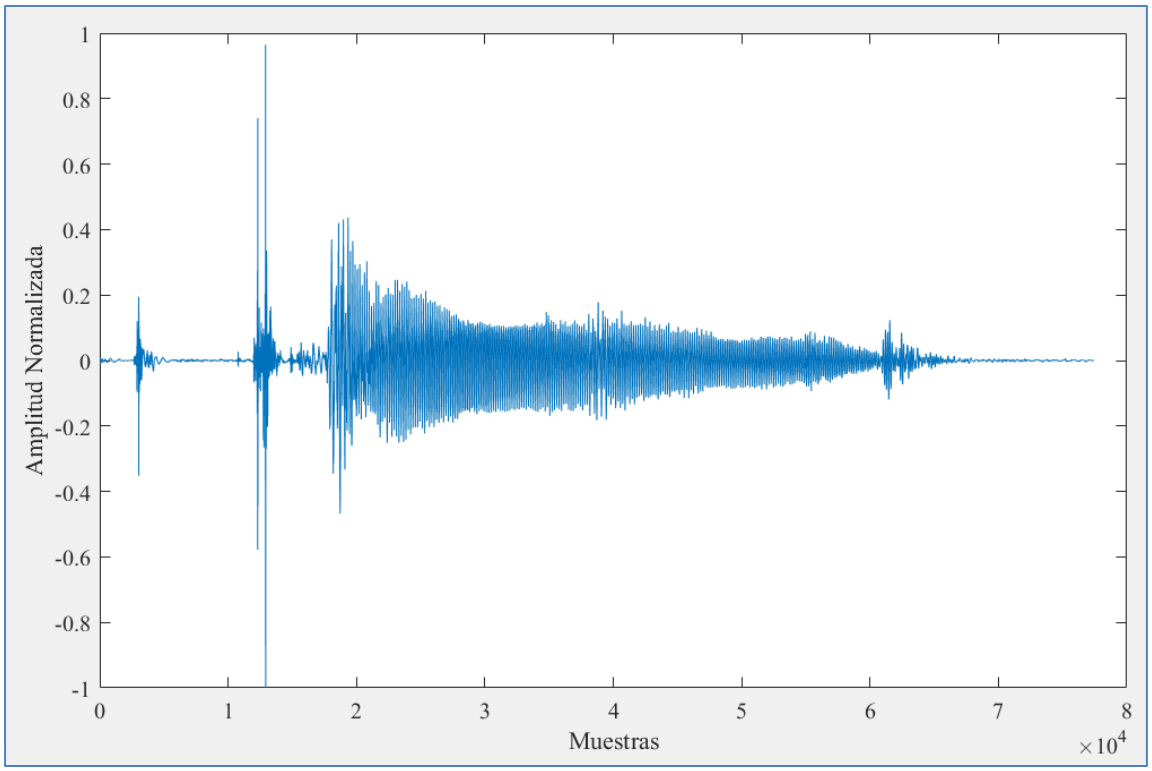

Figura 16. Forma normalizada, la amplitud no sobrepasa el rango de [-1,1]. Elaboración propia.

SEGMENTACIÓN DE MELODÍAS DE PRUEBA.

Para evaluar la precisión y eficacia del sistema de identificación de notas musicales, se ha utilizado una melodía simple como caso de prueba, específicamente la melodía de la conocida canción "*Estrellita, estrellita*". Esta elección se ha basado en la familiaridad y simplicidad de la melodía, lo que permite un análisis claro y comprensible de los resultados.

Al emplear una melodía sencilla y conocida, se ha facilitado la validación del sistema, ya que se pueden comparar las notas detectadas con las notas esperadas de manera directa y efectiva. Esta comparación ha sido fundamental para ajustar y optimizar los parámetros del modelo de clasificación.

Un aspecto importante del análisis ha sido el espectrograma de la señal de audio de la melodía. El espectrograma ha proporcionado una representación visual del contenido frecuencial de la señal a lo largo del tiempo, permitiendo identificar los cambios y patrones en las frecuencias que corresponden a las diferentes notas musicales. Esta herramienta ha resultado de gran valor para observar cómo se distribuyen las energías de las frecuencias en la señal, lo cual ha facilitado la identificación y segmentación de las notas individuales. Mediante el análisis del espectrograma, se ha logrado entender mejor la estructura temporal y frecuencial de la melodía, lo que ha sido esencial para mejorar la precisión del sistema de identificación de notas.

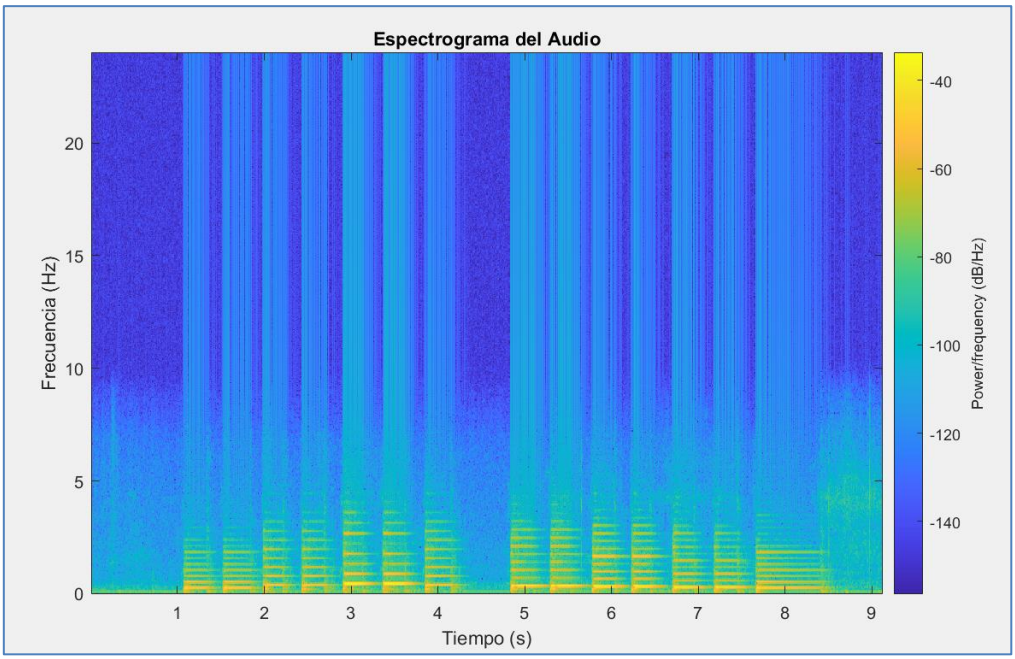

Figura 17. Espectrograma melodía de prueba. Elaboración propia.

A partir de esto, se decidió utilizar un método de energía localizada para segmentar el audio y analizar los segmentos detectados. Este método implicó calcular la energía de la señal en ventanas de tiempo específicas y encontrar los picos de energía, que suelen corresponder al ataque de la nota. Al haber detectado estos picos, se pueden identificar las ubicaciones en el tiempo, permitiendo segmentar el audio de manera precisa y enfocarse en los segmentos relevantes para la clasificación.

En la siguiente figura se pueden identificar los puntos correspondientes a las 14 notas presentes en la melodía, utilizando el método de energía localizada. Cada uno de estos puntos resalta claramente.

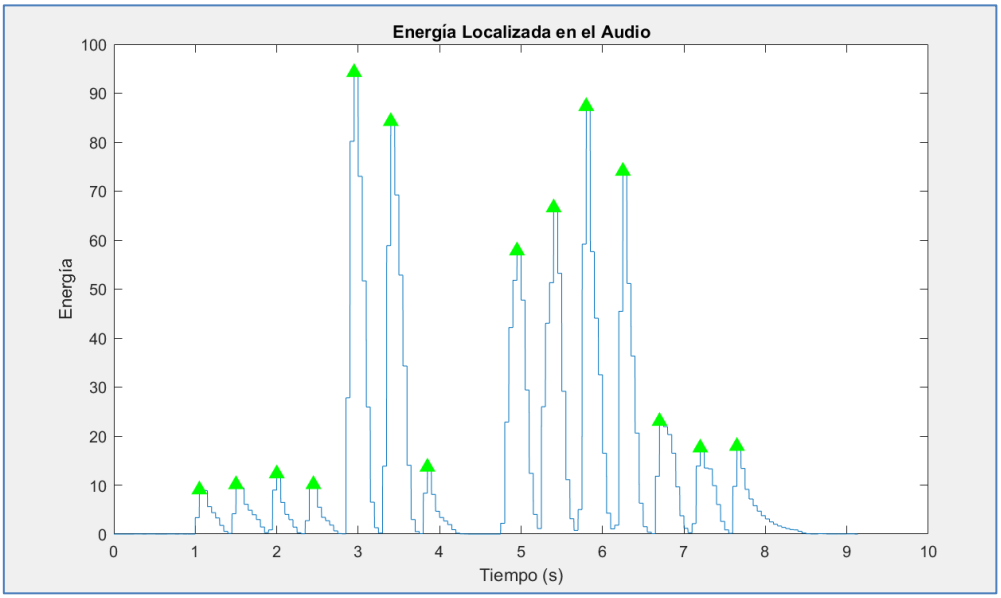

Figura 18. Energía localizada, marcados con triángulos verdes los puntos de los ataques a una nota. Elaboración propia.

Todas estas tareas garantizan que los datos estén limpios y sean adecuados para el entrenamiento efectivo del identificador de notas musicales.

3.1.3. EXTRACCIÓN DE CARACTERISTICAS PARA EL APRENDIZAJE

En esta etapa, se han extraído características relevantes de los archivos de audio que contenían las diferentes notas musicales. Se optó por utilizar los coeficientes MFCC, una técnica ampliamente utilizada en el procesamiento de señales de audio debido a su capacidad para capturar las características espectrales de un sonido de manera eficaz.

Los coeficientes MFCC proporcionaron una representación compacta pero informativa de la señal de audio. Como hemos visto, los coeficientes capturaron tanto la forma de la envolvente espectral como las características de la distribución de energía a lo largo del tiempo. La envolvente espectral refleja cómo variaba la energía de la señal en diferentes frecuencias, mientras que las características de distribución de energía permitían distinguir entre diferentes sonidos, como las vocales o los instrumentos musicales.

La representación, es especialmente apropiada para su empleo en combinación con los sistemas automáticos, pero sus resultados resultan difíciles de interpretar; a diferencia de lo que sucedía con los espectrogramas y formas de onda anteriores.

En esta implementación, se excluyeron los dos primeros coeficientes MFCC para reducir la redundancia y mejorar la eficiencia del modelo. La decisión de excluir el primer y segundo coeficiente MFCC se basó en una cuidadosa evaluación de su contribución a la representación de la señal de audio. Dado que el primer coeficiente estaba altamente correlacionado con la energía total de la señal, su inclusión podría haber introducido redundancia en el modelo y sesgado los resultados de clasificación. Por lo tanto, al excluirlo, se buscó mejorar la eficiencia del modelo al tiempo que se mantenía su capacidad para capturar las características más relevantes de la señal.

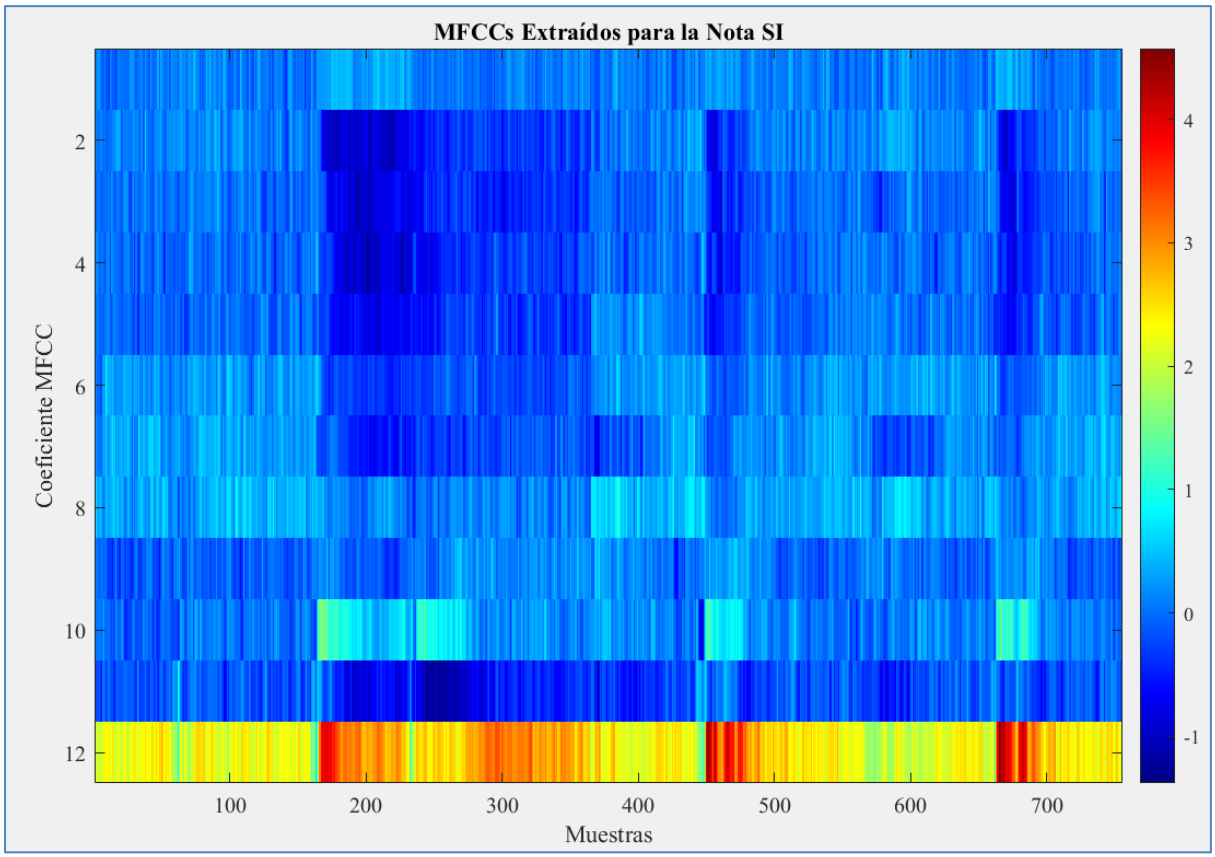

Figura 19. Representación gráfica de los MFCC tras la eliminación de los 2 primeros coeficientes, Elaboración propia.

3.2. MODELO BASADO EN LA FRECUENCIA DOMINANTE

En este trabajo, el primer experimento que se realiza para identificar la nota pulsada consiste en la detección de las frecuencias dominantes considerando cada posible nota pulsada de manera independiente en un registro segmentado por nota. Teniendo en cuenta todas las frecuencias características para cada nota que podemos encontrar en las 9 octavas de un piano, se realiza la clasificación de cada registro de audio de entrada para cada nota musical por separado, basándose en la selección de la frecuencia dominante, y seleccionando aquella nota cuyo registro previo se ajuste mejor a la nueva entrada.

3.2.1. FORMULACIÓN DEL SISTEMA PROPUESTO

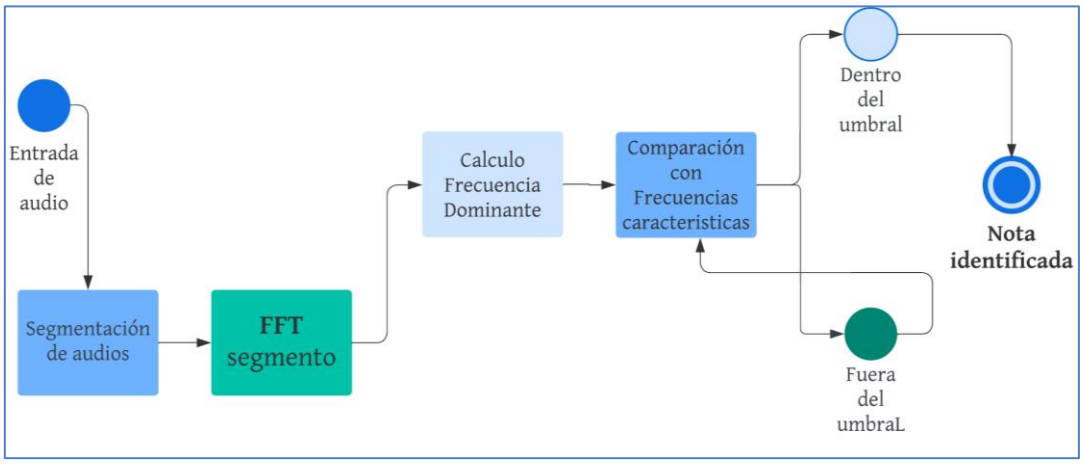

Figura 20. Diagrama de bloques empleado para la clasificación de registros según la nota dominante. Elaboración propia.

El proceso comenzó con la entrada de una señal de audio. Esta señal, en el caso de que fuese dos o más notas tocadas fue dividida en tantos segmentos como cantidad de notas detectadas hubiesen, cada uno diseñado para representar una nota musical específica.

Para la estimación de la frecuencia dominante de cada segmento, estos fueron sometidos a un análisis utilizando la Transformada de Fourier de la señal en ventanas cortas (FFT). Esta técnica permitió descomponer la señal en su espectro de frecuencias, lo que facilitó la identificación de las componentes frecuenciales predominantes en cada segmento específico de la señal de audio. El número de puntos de la FFT vendrá determinado por la longitud esperada de la señal de audio, si bien será posible aumentarla, o reducirla a conveniencia. Para la evaluación de la frecuencia dominante, obtendremos el valor máximo de la FFT en valor absoluto y su índice el cual indicará la frecuencia aproximada de la nota buscada. Esa frecuencia aproximada será la frecuencia dominante.

Para cada segmento analizado, se evaluó si la frecuencia dominante detectada coincidía con alguna de las frecuencias características asociadas a las notas musicales de un piano estándar. Esto se realizó estableciendo un criterio de comparación basado en márgenes de error predefinidos para cada frecuencia característica. Si la frecuencia dominante calculada estaba dentro del margen de error especificado para alguna nota, se consideraba que esa frecuencia correspondía a la nota en cuestión.

Los diferentes umbrales fijados que representaban el margen de error para cada octava, se podían ver aumentados en octavas más altas debido al crecimiento exponencial de las frecuencias en el piano, para poder tener un mayor margen de error en los intervalos más grandes entre notas consecutivas.

En la siguiente Figura se puede observar que, dentro del mismo rango de notas, pero en diferentes octavas, las diferencias de frecuencia son significativamente menores en las octavas más bajas en

comparación con las más altas. Por lo tanto, es viable aumentar el margen de error en las frecuencias más altas para una detección más efectiva.

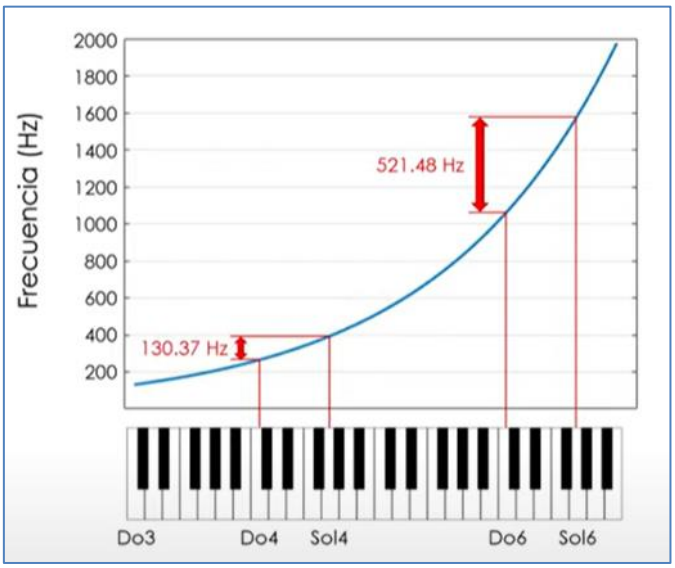

Figura 21. Curva exponencial de las notas musicales.

La selección de estos umbrales se realizó teniendo en cuenta las diferencias existentes entre notas consecutivas en cada octava. Para ello se divide entre dos el valor absoluto de dos frecuencias consecutivas de las mostradas en la Figura 5.

$$\left|\frac{f_1 - f_2}{2}\right|$$

Tras realizar estos cálculos para cada una de las octavas, se puede observar cómo los resultados se asemejan a un crecimiento exponencial, mencionado anteriormente, de 2^n. Por lo tanto, los umbrales finales se pueden determinar con a través de esa exponencial, quedando

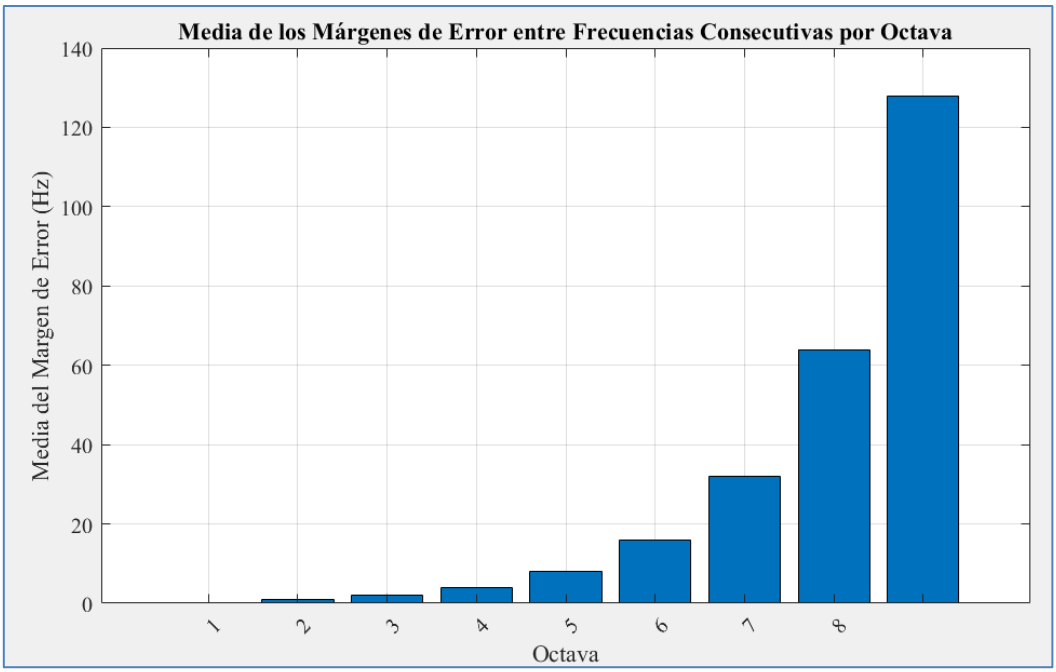

Figura 22. Diagrama de barras que representa la media de los márgenes de error calculados por octava. Elaboración propia.

Una vez estimada la frecuencia dominante, se realizan comparaciones del valor absoluto de la diferencia de esta con las frecuencias fijadas para cada nota. Cuando esta diferencia fuese menor que el umbral correspondiente se elija su respectiva nota asociada.

Luego de aplicar este proceso de comparación para todos los segmentos de la señal de audio, se seleccionó la nota cuya frecuencia característica coincidía más cercanamente con la frecuencia dominante detectada en el segmento correspondiente. Esta nota seleccionada se presentó como el resultado final del proceso de identificación.

3.2.2. PRUEBAS DESARROLLADAS

Antes de iniciar el análisis del audio, se definieron las notas musicales que se utilizarían como referencia para evaluar las predicciones del modelo. Estas notas fueron seleccionadas previamente y se almacenaron en una lista específica.

PRUEBA BÁSICA

Como prueba preliminar para este modelo, se utilizaron grabaciones de audio básicas realizadas con un teléfono móvil o también con un sintetizador de un ordenador y se analizaron sus espectros. Estas grabaciones consisten en la ejecución de una sola nota o un único acorde, lo que permite entender el análisis espectral de una o varias notas musicales

Como ejemplo se muestra en la siguiente figura el espectro del acorde de “Lam”, compuesto por las notas La, Do, Mi, cuyas frecuencias se pueden comparar con las de la tabla de la *Figura 2*.

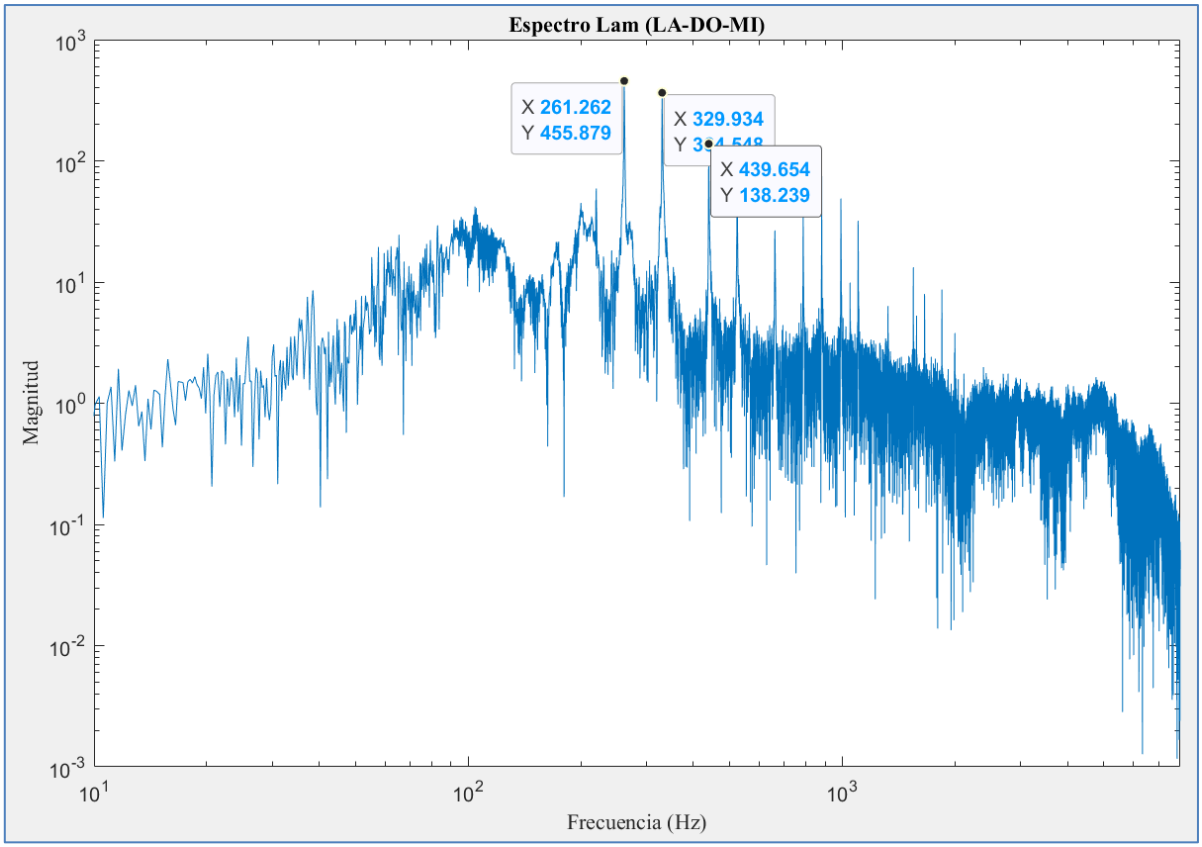

Figura 23. Contenido espectral que representa el acorde de Lam (La, Do, Mi), con sus respectivas frecuencias marcadas. Elaboración propia.

CARGA Y PROCESAMIENTO DEL ARCHIVO DE AUDIO

Se procedió a cargar el archivo de audio desde una ubicación específica en el sistema. Para asegurar la consistencia en el procesamiento, el audio se convirtió a formato mono, facilitando así la manipulación y análisis subsiguientes.

ANÁLISIS DE SEGMENTOS DE AUDIO:

Una vez identificados los puntos de interés en el espectro localizados gracias al análisis de los picos de energía, se procedió a segmentar el audio en intervalos específicos alrededor de estos puntos. Cada segmento fue cuidadosamente analizado para determinar la frecuencia dominante utilizando métodos como la transformada de Fourier, que permitió descomponer la señal en sus componentes espectrales.

CORRESPONDENCIA DE FRECUENCIAS A NOTAS MUSICALES

Las frecuencias dominantes obtenidas de cada segmento de audio fueron comparadas con listas predefinidas de frecuencias asociadas a notas musicales específicas. Este proceso requirió establecer criterios precisos para determinar si una frecuencia se ajustaba dentro de un margen de error aceptable para ser considerada como una nota musical particular.

PREDICCIÓN Y EVALUACIÓN

Con base en la correspondencia encontrada entre las frecuencias y las notas musicales predefinidas, se realizaron predicciones sobre las notas que podrían estar presentes en cada segmento de audio. Estas predicciones se evaluaron comparándolas con las notas de prueba definidas al inicio del proceso.

CÁLCULO DE LA TASA DE ACIERTOS

Para cuantificar la precisión del modelo, se calculó la tasa de aciertos, que representó el porcentaje de notas correctamente identificadas en relación con el total de notas de prueba. Este paso proporcionó una medida objetiva de la efectividad del modelo en el reconocimiento de las notas musicales presentes en el audio analizado.

3.3. DESARROLLO DEL CLASIFICADOR DISCRIMINANTE (SVM)

3.3.1. FORMULACIÓN DEL SISTEMA PROPUESTO

El segundo sistema propuesto se basa en la utilización de un clasificador de Máquinas de Vectores de Soporte (SVM) para llevar a cabo la tarea de identificación de notas musicales en una melodía dada. Esta formulación se compone de varios componentes clave que se interconectaron para lograr la tarea deseada.

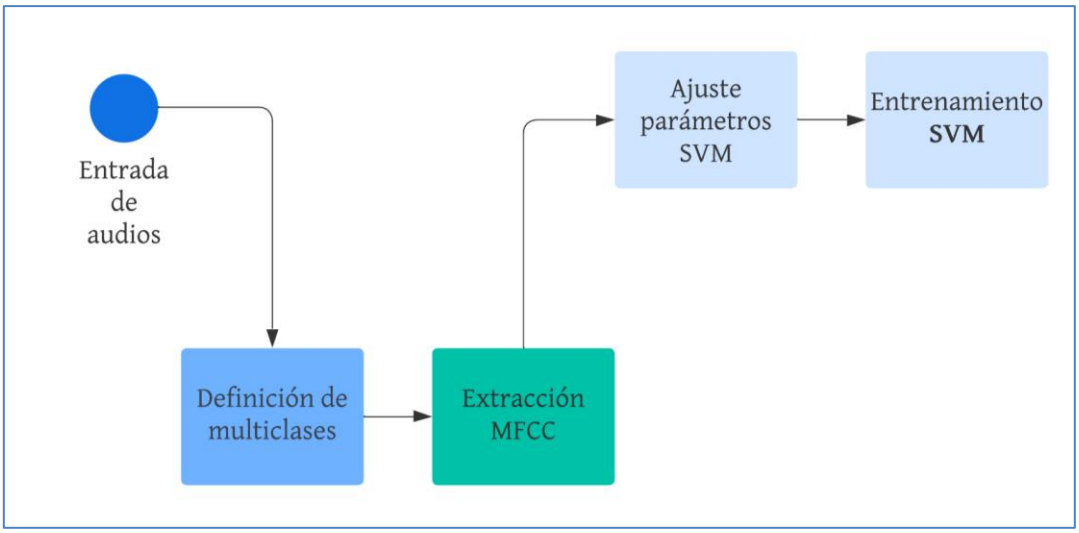

Figura 24. Diagrama de bloques del modelo de SVM. Elaboración propia.

Una vez extraídas las características de los archivos de audio utilizando los coeficientes MFCC, se procedió al entrenamiento del clasificador SVM. El SVM es un algoritmo de aprendizaje supervisado que busca encontrar el hiperplano óptimo que mejor separa las clases en el espacio de características.

Para cada nota musical, se entrenó un clasificador SVM individual utilizando los coeficientes MFCC correspondientes a esa nota como datos de entrada y una etiqueta de clase única como salida. Durante el proceso de entrenamiento, el SVM ajustó los parámetros del modelo, tales como el parámetro de regularización (C), el tipo de Kernel utilizado y el ancho de banda del Kernel RBF. Estos ajustes fueron importantes para maximizar la capacidad del modelo de separar eficazmente las diferentes clases de notas musicales.

El proceso de entrenamiento del clasificador SVM implicó encontrar un equilibrio óptimo entre la capacidad de generalización del modelo (su habilidad para clasificar correctamente nuevas muestras) y su capacidad para ajustarse a los datos de entrenamiento específicos. Esto se logró mediante la optimización de los parámetros del modelo durante el proceso de entrenamiento, asegurando así que el SVM pudiera capturar las características distintivas de cada nota musical basadas en los coeficientes MFCC extraídos.

Tras el entrenamiento del SVM, se realizó un PCA (Análisis de Componentes Principales) de características MFCC (Coeficientes Cepstrales de Frecuencia Melódica) calculados para los registros empleados en el entrenamiento de las máquinas. El PCA se utiliza para reducir la dimensionalidad de los datos y visualizar las relaciones entre diferentes clases en un espacio de menor dimensión. En este caso, se ha reducido a dos componentes principales, permitiendo visualizar los datos en un plano 2D.

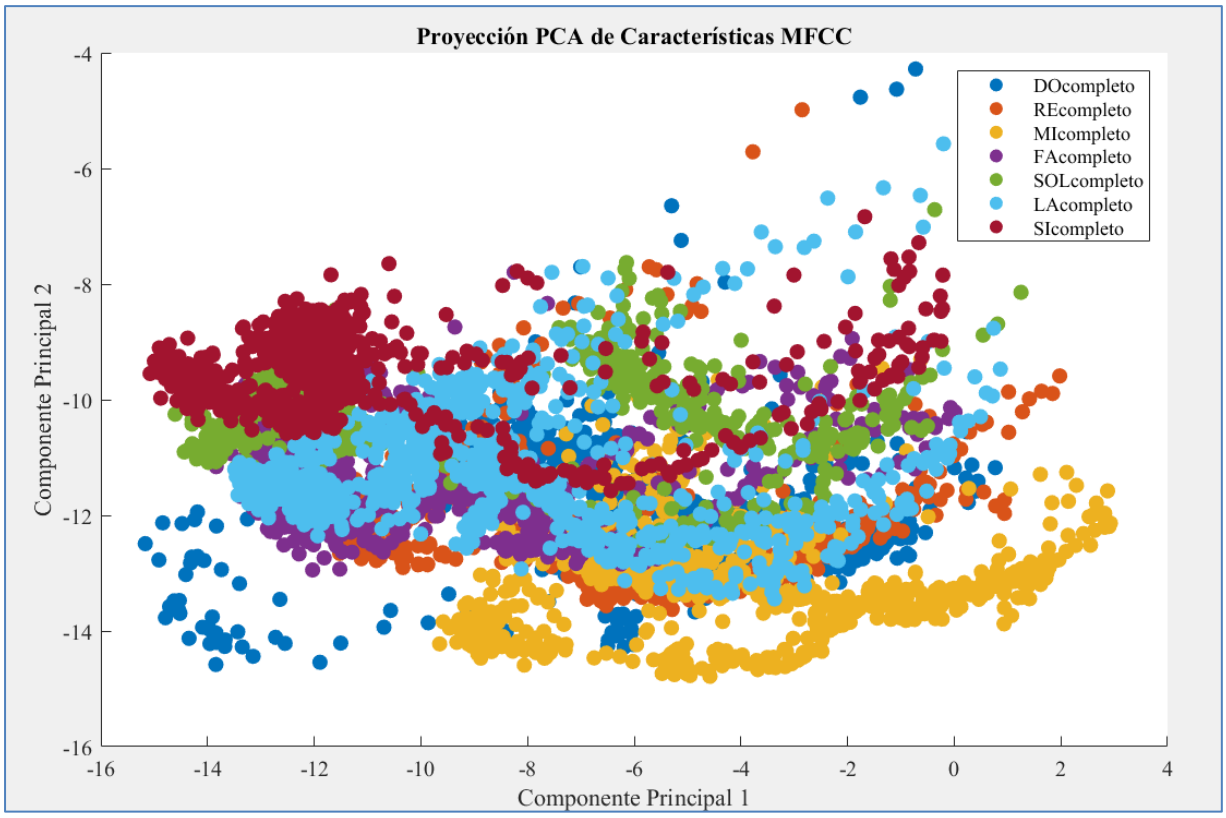

Figura 25. Proyección PCA de los datos de entrenamiento del SVM. Elaboración propia.

Esta visualización permite observar cómo se agrupan las diferentes clases después del proceso de clasificación, proporcionando una idea de la eficacia del modelo SVM para distinguir entre las diferentes notas musicales basadas en las características MFCC.

ELEMENTOS Y COMPLEJIDAD DEL ENTRENAMIENTO:

El proceso de entrenamiento de un sistema de identificación de notas musicales basado en una Máquina de Vectores de Soporte (SVM) implica múltiples elementos críticos y una serie de pasos complejos que afectan el rendimiento y la precisión del modelo. A continuación, se describen en detalle los elementos clave y la complejidad asociada con el entrenamiento del modelo.

La calidad y representatividad del conjunto de datos utilizados para entrenar el clasificador SVM fueron críticas para su rendimiento. Se aseguró de que el conjunto de datos abarcara una variedad suficiente de muestras de cada clase de notas musicales para que el clasificador pudiera aprender patrones distintivos entre ellas.

El rendimiento del clasificador SVM dependió en gran medida de la selección adecuada de hiperparámetros, como el parámetro de regularización (C) y los parámetros del Kernel (tipo de Kernel y ancho de banda en el caso de Kernel RBF). Se llevó a cabo un proceso de ajuste de hiperparámetros utilizando técnicas como la validación cruzada para encontrar la combinación óptima que maximizara la capacidad de generalización del modelo.

Se dedicó tiempo a la elección del tipo de Kernel y sus parámetros asociados, ya que esto podía afectar significativamente la capacidad del clasificador SVM para separar las clases en el espacio de características. Se exploraron diferentes tipos de Kernel, como el Kernel lineal, polinomial o RBF, y se realizaron ajustes en sus parámetros para optimizar el rendimiento del modelo.

Durante el entrenamiento, se buscó encontrar un equilibrio entre sesgo y varianza para evitar el sobreajuste o subajuste del modelo a los datos de entrenamiento. Se realizaron ajustes en los hiperparámetros y se seleccionó cuidadosamente el conjunto de datos de entrenamiento para lograr este equilibrio y garantizar que el modelo fuera capaz de capturar la estructura subyacente de los datos sin capturar el ruido.

El entrenamiento del clasificador SVM fue computacionalmente intensivo, especialmente debido al tamaño del conjunto de datos y la dimensionalidad de las características. Se implementaron técnicas de optimización y paralelización para acelerar el proceso de entrenamiento y manejar la complejidad computacional asociada con conjuntos de datos grandes y características de alta dimensionalidad.

3.4. DESARROLLO DEL MODELO BASADO EN TÉCNICAS GENERATIVAS CLÁSICAS (GMM)

3.4.1. FORMULACIÓN DEL SISTEMA PROPUESTO

El presente estudio se centró en la implementación y evaluación de Modelos de Mezclas Gaussianas (GMM) como método para el reconocimiento automático de notas musicales. Este enfoque se caracteriza por su capacidad para modelar distribuciones probabilísticas de características extraídas de señales de audio, específicamente mediante coeficientes cepstrales de frecuencia melódica (MFCC).

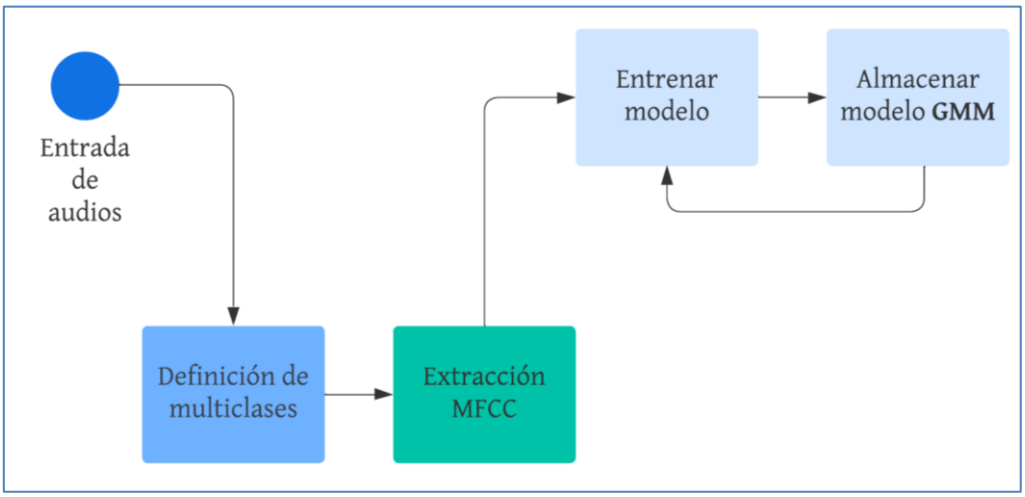

Figura 26. Diagrama de bloques modelo GMM. Elaboración propia. Tomada en mayo.

Inicialmente, se definió un conjunto de datos que incluía grabaciones de siete notas musicales: DO, RE, MI, FA, SOL, LA y SI, cada una representada por múltiples archivos de audio. Cada archivo de audio se cargó y se normalizó para asegurar una consistencia en la amplitud de las señales. Posteriormente, se aplicó la extracción de características mediante MFCC para cada grabación.

Los coeficientes MFCC capturan las características espectrales de las notas musicales, ofreciendo una representación compacta pero informativa de cada segmento de audio. Se configuró el número de coeficientes en 13, excluyendo los dos primeros coeficientes para eliminar la componente de energía.

Con los datos de MFCC preparados, se procedió a entrenar los modelos GMM para cada una de las siete notas musicales. Se exploró una configuración de cinco componentes gaussianos por modelo, ajustándose el parámetro de regularización para optimizar la generalización y evitar sobreajustes.

El proceso de entrenamiento de GMM implica modelar la distribución de probabilidad de los datos de entrenamiento, representando cada nota musical como una mezcla ponderada de distribuciones gaussianas. Esta técnica es especialmente efectiva para modelar la variabilidad intrínseca de las características espectrales de cada nota.

A continuación, se muestran los gráficos resultantes de dispersión y sus contornos ajustados de la mezcla gaussiana para cada nota calculada. Sobre ellos se han sobrepuesto las muestras que dieron lugar al modelo. A pesar de ello, es posible identificar los contornos (curvas) que delimitan las regiones entradas por el modelo GMM para cada nota.

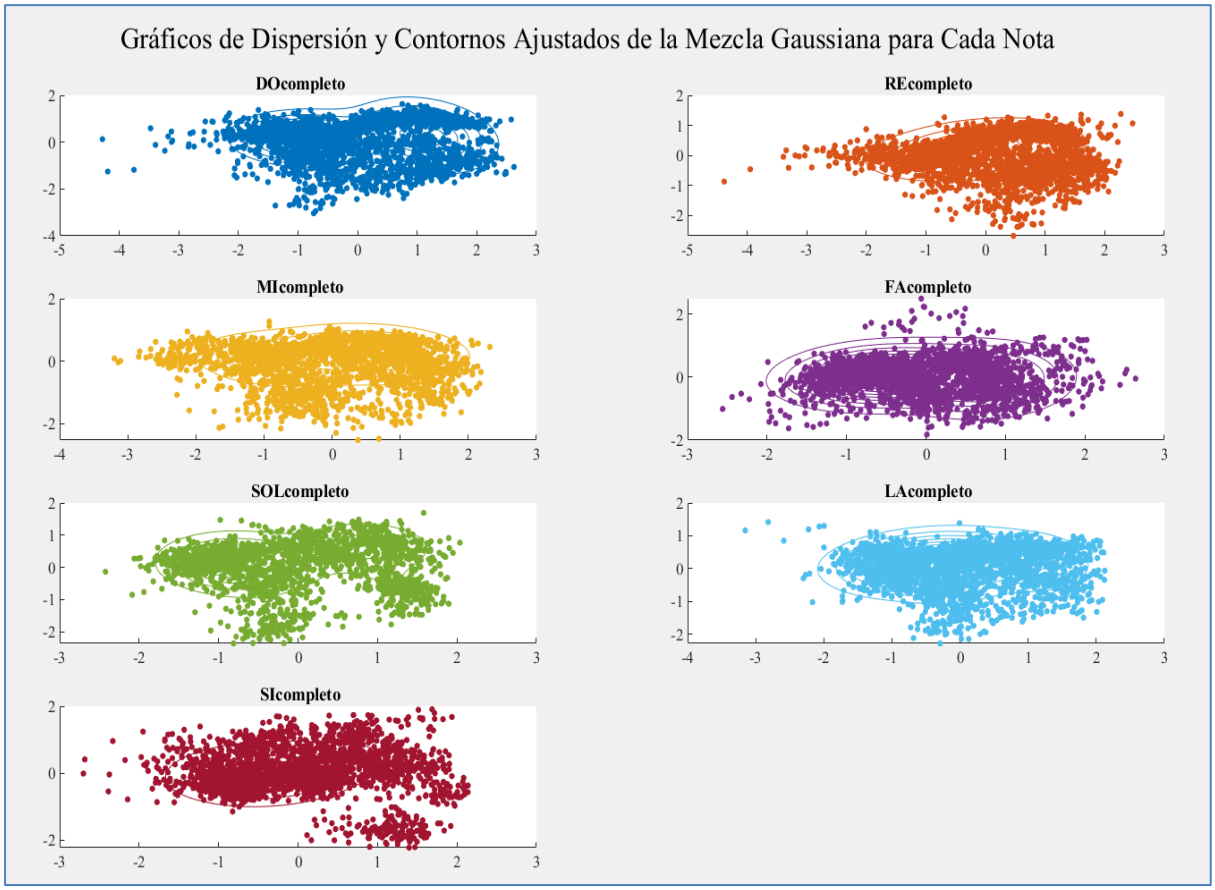

Figura 27. Gráfica de dispersión de la mezcla gaussiana por nota. Elaboración propia.

La Figura muestra gráficos de dispersión y contornos ajustados de una Mezcla Gaussiana (GMM) para cada nota musical (DO, RE, MI, FA, SOL, LA, SI). Cada gráfico representa los datos correspondientes a una nota específica y los puntos en el plano bidimensional muestran las observaciones de los datos después del entrenamiento del modelo GMM.

En cada gráfico, los puntos dispersos indican las posiciones de las observaciones en el espacio de características, mientras que los contornos elípticos representan las distribuciones gaussianas que el modelo GMM ha ajustado a los datos. Estos contornos elípticos ayudan a visualizar cómo el modelo GMM agrupa los datos en diferentes componentes gaussianos, mostrando las regiones de mayor densidad de datos y la forma en que los datos están distribuidos.

El propósito de estos gráficos es proporcionar una comprensión visual de cómo el modelo GMM ha identificado y ajustado las distribuciones gaussianas para cada conjunto de datos de las notas musicales, facilitando así la interpretación de los patrones y estructuras subyacentes en los datos.

ELEMENTOS Y COMPLEJIDADES DEL MODELO

La elección del número óptimo de componentes en el GMM y la aplicación adecuada de técnicas de regularización fueron desafíos significativos. Estos aspectos influyeron directamente en la capacidad del modelo para generalizar de manera efectiva los patrones de melodía y evitar el sobreajuste a datos específicos de entrenamiento.

Evaluar la precisión del modelo GMM en la tarea de reconocimiento de melodías implicó la comparación sistemática entre las predicciones del modelo y las notas musicales reales. La validación cruzada y la evaluación con conjuntos de datos de prueba fueron esenciales para garantizar la fiabilidad y robustez del sistema en diferentes condiciones y variaciones de datos.

El procesamiento de múltiples archivos de audio y la aplicación de operaciones matemáticas intensivas para el entrenamiento y el funcionamiento del GMM representaron desafíos en términos de eficiencia computacional. Optimizar estos aspectos fue importante para mantener tiempos de respuesta aceptables y aprovechar al máximo los recursos disponibles.

Interpretar los resultados del modelo GMM en el contexto musical y ajustar los parámetros según las características específicas de las grabaciones musicales fueron aspectos complejos. La capacidad del modelo para adaptarse a diferentes estilos de interpretación musical y variaciones en la ejecución fue fundamental para su aplicabilidad práctica y su utilidad en escenarios del mundo real.

3.5. DESARROLLO DEL MODELO BASADO EN TÉCNICAS GENERATIVAS PROFUNDAS (LSTM)

3.5.1. FORMULACIÓN DEL SISTEMA PROPUESTO

En este proyecto, se llevó a cabo el desarrollo de una red neuronal LSTM (Long Short-Term Memory) para la identificación de notas musicales a partir de archivos de audio. Utilizando coeficientes MFCC como características principales, se entrenó la red para clasificar secuencias de audio en distintas categorías de notas. El objetivo fue crear un modelo robusto y preciso que pudiera reconocer patrones temporales en los datos de audio, aprovechando las capacidades avanzadas de las redes LSTM para manejar dependencias a largo plazo y variaciones en las secuencias de entrada.

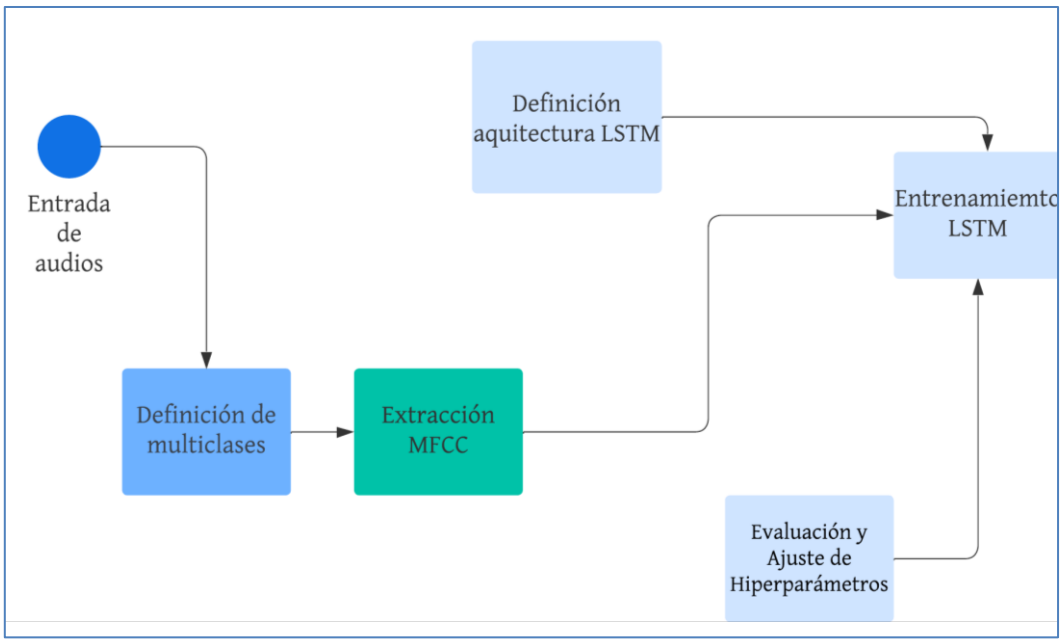

Figura 28. Diagrama de bloques para el entrenamiento de LSTM. Elaboración propia.

El proceso comenzó con la preparación de los datos de audio correspondientes a diferentes notas musicales. Para cada nota, se cargaron varios archivos de audio y se normalizaron para asegurar una amplitud uniforme. A continuación, se extrajeron características específicas de los audios, conocidas como coeficientes MFCC.

Después de obtener los coeficientes MFCC de cada archivo de audio, se almacenaron todos estos datos en una estructura de datos para su procesamiento posterior. Cada conjunto de coeficientes se organizó de manera que las secuencias completas de vectores de características estuvieran listas para ser utilizadas en el entrenamiento de la red neuronal.

Para preparar los datos para la red neuronal, se crearon secuencias que contenían estos coeficientes y se asignaron etiquetas correspondientes a cada nota musical. Estas etiquetas se convirtieron en un formato adecuado para su uso en la clasificación.

Luego, se definió la arquitectura de la red neuronal. Esta red combinó varias capas, incluyendo capas convolucionales y de normalización, que ayudaron a detectar patrones en las secuencias de coeficientes MFCC. Se muestra a continuación un diagrama de flujo del proceso una vez extraídos los MFCC.

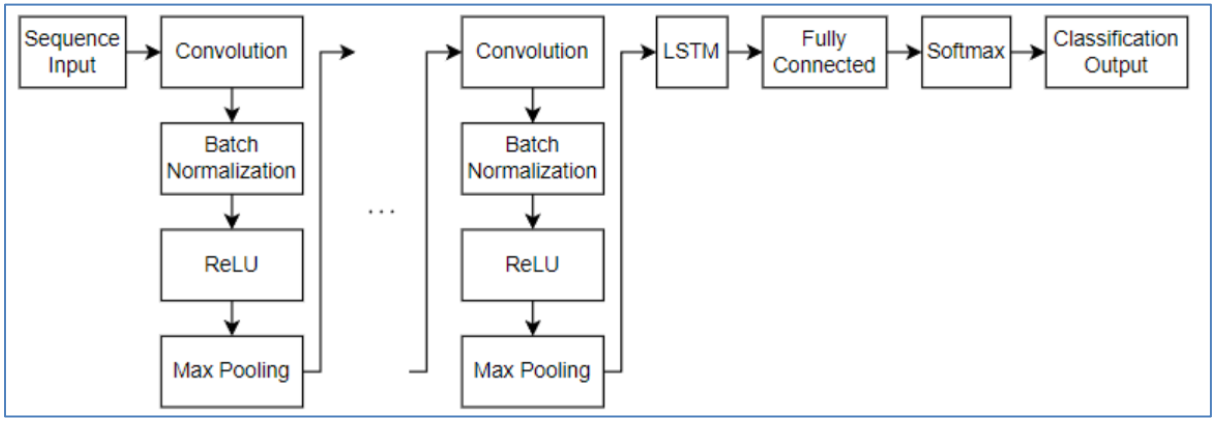

Figura 29. Diagrama que incluye todas las capas que se aplican en este LSTM. Tomada de en junio.

El primer conjunto de capas del modelo fueron las convolucionales, que aplicaron filtros específicos para detectar patrones locales en las secuencias de MFCCs. Estos filtros ayudaron a identificar características importantes, como los armónicos y las transiciones de frecuencia que distinguían una nota musical de otra. La salida de las capas convolucionales se normalizó mediante la técnica de normalización por lotes, lo que aseguró que las activaciones tuvieran una distribución uniforme, facilitando así el entrenamiento y mejorando la estabilidad del modelo. La activación ReLU introdujo no linealidad en el modelo, permitiendo aprender representaciones más complejas y detalladas de las características acústicas.

Para reducir la dimensionalidad y destacar las características más prominentes, se utilizó una capa de agrupamiento máximo (max pooling). Esta capa redujo la variabilidad espacial al tomar el valor máximo dentro de una ventana de agrupamiento, lo que ayudó a resaltar las características más importantes de las notas musicales. Este proceso de convolución, normalización, activación y agrupamiento se repitió varias veces para permitir al modelo extraer características de alto nivel y capturar patrones más complejos en las secuencias de MFCCs. Estas repeticiones fueron RELEVANTES para que el modelo pudiera manejar la diversidad y complejidad de los archivos de audio utilizados para entrenar el identificador de notas.

Después de la extracción de características locales a través de las capas convolucionales, la secuencia resultante de MFCCs se pasó a una capa LSTM. Las redes LSTM fueron conocidas por su capacidad para capturar dependencias a largo plazo en secuencias de datos, lo cual fue crucial para la identificación de notas musicales, ya que la información relevante podía estar distribuida a lo largo del tiempo. La

capa LSTM retuvo y procesó esta información temporal, produciendo una representación coherente que reflejaba la evolución de las características acústicas a lo largo del tiempo.

Finalmente, la salida de la LSTM se pasó por una capa totalmente conectada, que integró todas las características aprendidas y las preparó para la clasificación final. La capa *softmax* convirtió las salidas de la capa totalmente conectada en probabilidades, asignando una probabilidad a cada posible nota musical. La capa de salida de clasificación proporcionó la nota musical prevista, basándose en la probabilidad más alta determinada por la capa *softmax*. Este enfoque permitió al modelo identificar y diferenciar entre diversas notas musicales con alta precisión, utilizando una variedad de archivos de audio correspondientes a cada nota durante el entrenamiento. De esta manera, el modelo combina eficazmente las capacidades de las convoluciones para extraer características locales y las LSTM para capturar la dinámica temporal, ofreciendo una solución robusta y eficaz para la clasificación de notas musicales.

ELEMENTOS Y COMPLEJIDADES DEL MODELO

La arquitectura de la red neuronal se compone de capas convolucionales, diseñadas para extraer características locales significativas de los coeficientes MFCC. Estas capas son seguidas por una capa LSTM, especializada en capturar y aprender las dependencias temporales a largo plazo presentes en los datos de audio, facilitando así el reconocimiento de patrones musicales y variaciones temporales complejas. Computacionalmente, este proceso es muy costoso debido a la necesidad de procesar grandes volúmenes de datos y realizar numerosas operaciones matemáticas en cada capa.

Además de las capas convolucionales y LSTM, la red incluye capas totalmente conectadas que transforman las características aprendidas en predicciones probabilísticas sobre las clases de notas musicales. Esto se logra mediante una capa *softmax* al final de la red, proporcionando una salida interpretable y útil para la clasificación final.

El proceso de entrenamiento se ha optimizado utilizando técnicas avanzadas como el algoritmo Adam, que ajusta los parámetros de la red para minimizar la función de pérdida a lo largo de múltiples épocas de entrenamiento. La gestión de secuencias variables de datos MFCC y la configuración óptima de parámetros son desafíos críticos que requieren estrategias de preprocesamiento y ajuste fino, respectivamente.

El entrenamiento de una red neuronal LSTM para la clasificación de notas musicales desde archivos de audio combina técnicas avanzadas de procesamiento de señales con desafíos relacionados con la preparación de datos y la optimización de la arquitectura de la red. Esto asegura un modelo robusto y preciso capaz de capturar eficazmente las complejidades musicales y proporcionar una clasificación confiable de las notas en diversos contextos.

3.6. PRUEBAS PARA LAS MAQUINAS DE APRENDIZAJE

Se realizaron pruebas para medir el rendimiento de cada modelo. Estas pruebas fueron comunes para los tres modelos de aprendizaje, SVM, GMM y para la red neuronal LSTM.

Para evaluar el rendimiento del sistema de reconocimiento de notas musicales basado en máquinas de aprendizaje, se utilizó como entrada una melodía de prueba compuesta por varias notas musicales, cuyas identidades se conocían a priori. Se implementó un análisis sistemático variando dos parámetros clave: el tamaño de ventana y el solapamiento entre ventanas durante el procesamiento de la melodía de prueba.

CONFIGURACIÓN DE PARÁMETROS PARA EL ANÁLISIS

Se establecieron los parámetros para el análisis, incluyendo diferentes tamaños de ventana y solapamientos. Los tamaños de ventana fueron desde 100 ms hasta 300 ms en incrementos de 10 ms, mientras que los solapamientos varían desde 10% hasta 90% en incrementos de 5%. Se inicializó la matriz para almacenar las tasas de acierto correspondientes a cada combinación de tamaño de ventana y solapamiento.

PROCESAMIENTO DE LA SEÑAL DE AUDIO Y EXTRACCIÓN DE CARACTERÍSTICAS

La melodía de prueba fue procesada mediante técnicas de segmentación de señales para obtener segmentos de audio discretos. Cada segmento se sometió a un análisis detallado para extraer características significativas, en este caso los MFCC, utilizando técnicas especializadas de análisis de coeficientes relevantes para la detección de notas musicales.

MODELADO

Cada segmento de audio, centrado en las ubicaciones de máximos de energía encontrados, se normaliza y se calculan los coeficientes MFCC, excluyendo los dos primeros coeficientes. Estos coeficientes se utilizan como características de entrada para los modelos entrenados para cada nota musical.

EVALUACIÓN DE PRECISIÓN

Las notas detectadas automáticamente por los modelos se compararon con las notas reales presentes en la melodía de prueba. Se calculó una tasa de aciertos para evaluar la precisión del modelo en la identificación de las notas musicales, que posteriormente se presentarán como tablas en el apartado de resultados.

Los modelos fueron entrenados y probados utilizando diferentes tamaños de ventana (desde 40 ms hasta 300 ms) y diferentes porcentajes de solapamiento (desde 0.25 hasta 0.4).

4. RESULTADOS Y DISCUSIÓN

En este capítulo se expondrán los resultados obtenidos tras las pruebas realizadas para cada modelo.

Se utilizaron audios, tanto notas individuales como melodías, grabados directamente con el micrófono del móvil. Además, se utilizaron audios sacados por un teclado MIDI a través de un DAW y audios de notas extraídos de internet. Los sonidos grabados se generaron con un piano, o con herramientas que al menos tratarán de emular el sonido de este instrumento.

4.1. RESULTADOS EXTRACCIÓN FRECUENCIA DOMINATE

RESULTADOS PRUEBA BÁSICA

Se han realizado pruebas con mínimo 1 o 2 notas de cada octava. Con los audios del móvil en las frecuencias medias y altas el clasificador acierta, pero en las frecuencias más bajas no, desde el RE3 hasta la frecuencia más baja, el clasificador tiende a fallar el nombre de la nota. La frecuencia dominante del espectro no coincide en algunos casos con la frecuencia que corresponde a la nota. Sin embargo, con los audios sacados por el teclado MIDI no existen dichos fallos, funciona tanto en frecuencias bajas como en altas.

En las siguientes imágenes se puede observar como el clasificador acierta las notas propuestas. Siendo un RE5 y un RE6 y falla la nota RE3 ya que detecta que la frecuencia con la mayor amplitud es la que pertenece a un LA4 (440Hz) en vez de la que debería haber percibido (146.94 Hz). Este error puede deberse a que los teléfonos móviles al grabar alteran la grabación por distintos factores como las limitaciones técnicas del dispositivo para frecuencias bajas o la existencia de ruido ambiental en el entorno.

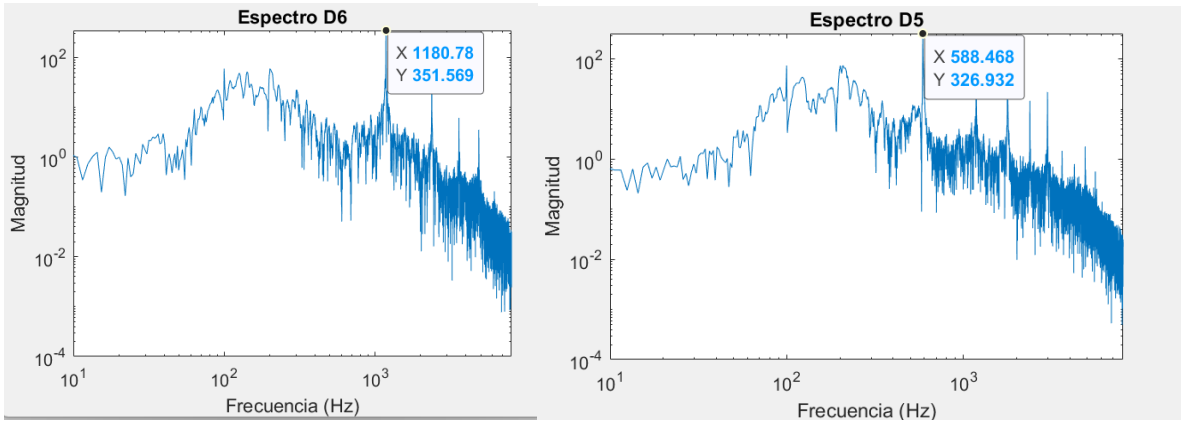

Figura 7: Ejemplos de acierto. Se observa como las frecuencias dominantes halladas coinciden con la frecuencia de las notas introducidas. Elaboración propia.

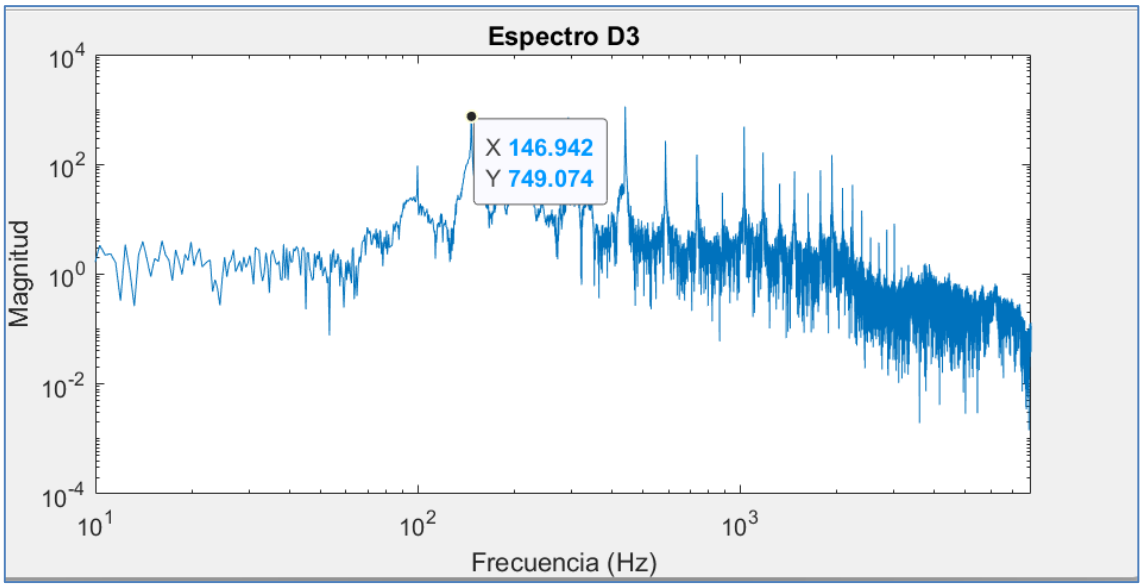

Figura 30. Ejemplo de error, se observa como la frecuencia dominante no coincide con la que realmente corresponde a un Re3. Elaboración propia. Tomada en octubre.

En las imágenes anteriores, se puede observar que el programa es muy efectivo para identificar una nota por golpe captado. Sin embargo, nuestro objetivo a largo plazo es detectar y clasificar notas tocadas simultáneamente, como en el caso de los acordes. Esto requerirá un análisis más exhaustivo del espectro para identificar correctamente las notas, ya que los acordes contienen múltiples frecuencias dominantes. Actualmente, el algoritmo desarrollado solo puede identificar notas basándose en una única frecuencia dominante, lo que no es adecuado para la clasificación de acordes. Debido a esta limitación, este método no sería útil ni efectivo para la tarea, ya que clasifica únicamente en función de la frecuencia dominante.

PRUEBA MELODIA

Las notas musicales fueron extraídas y comparadas con una serie de frecuencias predefinidas para determinar su correspondencia. El algoritmo ha sido evaluado utilizando un conjunto de prueba que contenía las siguientes notas musicales: DO, DO, SOL, SOL, LA, LA, SOL, FA, FA, MI, MI, RE, RE, DO.

TASA DE ACIERTOS

Tras realizar las pruebas con la misma melodía tocada en las 9 diferentes octavas del piano. El algoritmo ha logrado una media de tasa de aciertos del 97% en la identificación de las notas musicales del conjunto de prueba. Esto indica que todas las notas fueron correctamente identificadas de acuerdo con las frecuencias predefinidas y el margen de error establecido.

Se muestra a continuación una gráfica que representa la tasa de aciertos en cada octava:

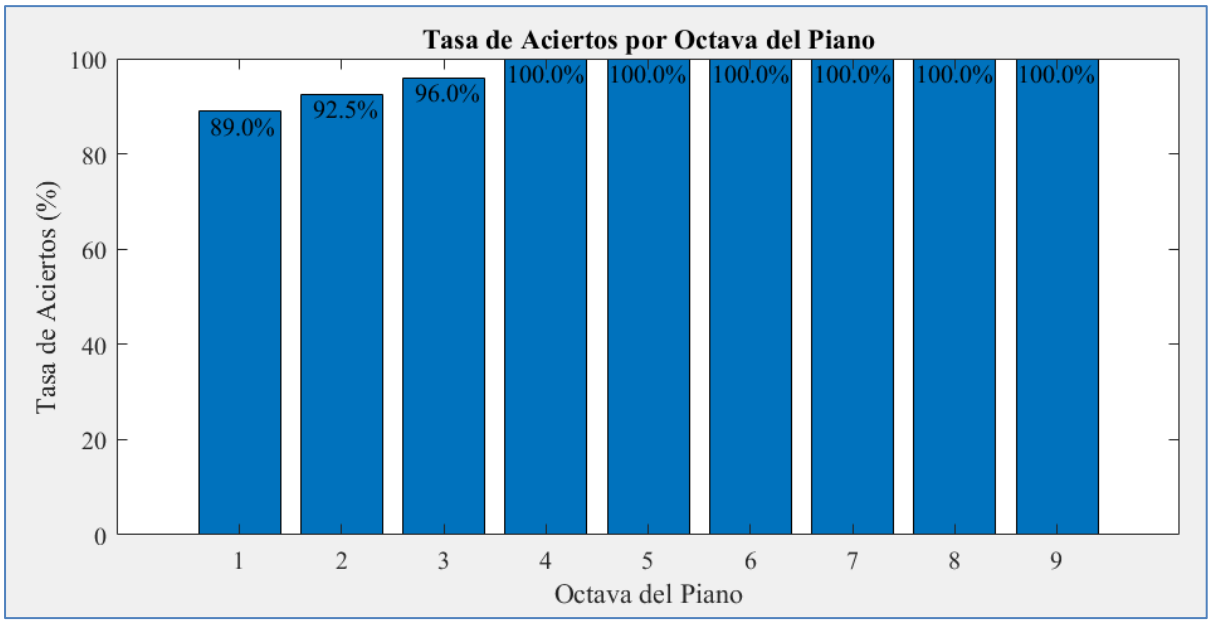

Figura 31. Tasa de aciertos de la identificación de notas por frecuencia dominante por octava. Elaboración propia. Tomada en mayo.

RESULTADOS DE PRECISIÓN

Los resultados obtenidos demuestran la robustez y precisión del algoritmo propuesto para la identificación automática de notas musicales en archivos de audio. La efectividad del 97% observada en la prueba en condiciones controladas subraya su potencial aplicación en aplicaciones de análisis musical automatizado, aunque se recomienda considerar las limitaciones mencionadas en situaciones más complejas de interpretación musical. A pesar de esta efectividad completa este método no llega a ser tan útil si lo que queremos es identificar una secuencia de acordes.

VISUALIZACIÓN Y PRESENTACIÓN DE RESULTADO

Finalmente, los resultados del análisis fueron visualizados mediante gráficos como espectrogramas y representaciones de la transformada de Fourier. Estas visualizaciones ayudaron a interpretar y comunicar de manera efectiva cómo el modelo había procesado y reconocido las notas musicales en el archivo de audio evaluado.

CONSIDERACIONES SOBRE LA EXTRACCIÓN DE FRECUENCIA FUNDAMENTAL

Es importante destacar que la extracción de la frecuencia fundamental mediante este algoritmo es completamente efectiva en casos de melodías básicas sin complejidades, como melodías simples. En situaciones donde se presentan acordes o notas en octavas muy bajas, la precisión puede verse afectada por la superposición de frecuencias.

4.2. RESULTADOS CLASIFICADOR SVM

El presente apartado se enfoca en los resultados obtenidos al utilizar Máquinas de Vectores de Soporte (SVM) para la tarea de reconocimiento de notas musicales. Este método ha sido evaluado considerando diferentes configuraciones de tamaño de ventana y solapamiento (solapamiento), dado que estas variables influyen significativamente en su desempeño.

INFLUENCIA DEL TAMAÑO DE VENTANA

El tamaño de ventana es un parámetro crítico en el procesamiento de señales de audio. Ventanas más pequeñas (p.ej., 40 ms) permiten una mayor resolución temporal, pero pueden no capturar adecuadamente las características espectrales de las notas musicales. Ventanas más grandes (p.ej., 300 ms) ofrecen una mejor resolución frecuencial, pero pueden incluir más ruido y variabilidad no deseada.

Los resultados mostraron que el rendimiento del SVM varía significativamente con el tamaño de la ventana. Ventanas intermedias (alrededor de 100 ms a 150 ms) lograron un equilibrio óptimo entre resolución temporal y frecuencial, proporcionando las tasas de acierto más altas. Ventanas demasiado pequeñas o demasiado grandes tendieron a reducir la precisión del clasificador.

INFLUENCIA DEL SOLAPAMIENTO

El solapamiento entre ventanas consecutivas también afecta la precisión del clasificador. Un solapamiento bajo (p.ej., 0.25) puede resultar en una menor cantidad de datos redundantes, lo que podría no ser suficiente para capturar la continuidad temporal de las notas. Un solapamiento alto (p.ej., 0.4) aumenta la redundancia, lo que puede ser beneficioso, pero también puede introducir ruido.

Se observó que un solapamiento moderado (alrededor de 0.35) ofreció los mejores resultados en términos de tasa de acierto. Esto permitió al SVM capturar mejor las transiciones suaves entre notas sin introducir excesiva redundancia.

USO DE REPRESENTACIONES EXTENDIDAS

Adicionalmente a todo lo anterior, también cabe realizar modificaciones en nuestra forma de representar los sonidos. Si bien en todo momento nos apoyamos en la representación MFCC, la literatura describe variantes sobre ésta orientadas al modelado de la información dinámica. En particular, el empleo de información sobre las diferencias entre ventanas subyacentes ha ofrecido importantes mejoras en el funcionamiento de los sistemas. El procedimiento se basa en extender la representación MFCC dada, incorporando componentes adicionales que caracterizan las variaciones con diferentes distancias de ventana. Por ejemplo, a las dos adyacentes (distancia 1, coeficientes Δ) o a las 4 más próximas (distancia 2, coeficientes $\Delta\Delta$).

Este tipo de representaciones no eleva en exceso la complejidad en las estimaciones de las representaciones o el tiempo de cómputo, si aumentan considerablemente la dimensionalidad del espacio de características (potencialmente x2, y x3 si se emplean todas a la vez).

RESULTADOS DE PRECISIÓN

La precisión del clasificador SVM fue evaluada exhaustivamente, alcanzando una tasa máxima de acierto del 64%. Este desempeño resalta la efectividad del SVM en la tarea de reconocimiento de notas musicales bajo las configuraciones óptimas de tamaño de ventana y solapamiento.

La tabla siguiente resume las tasas de acierto promedio obtenidas con el SVM para diferentes combinaciones de tamaño de ventana y solapamiento:

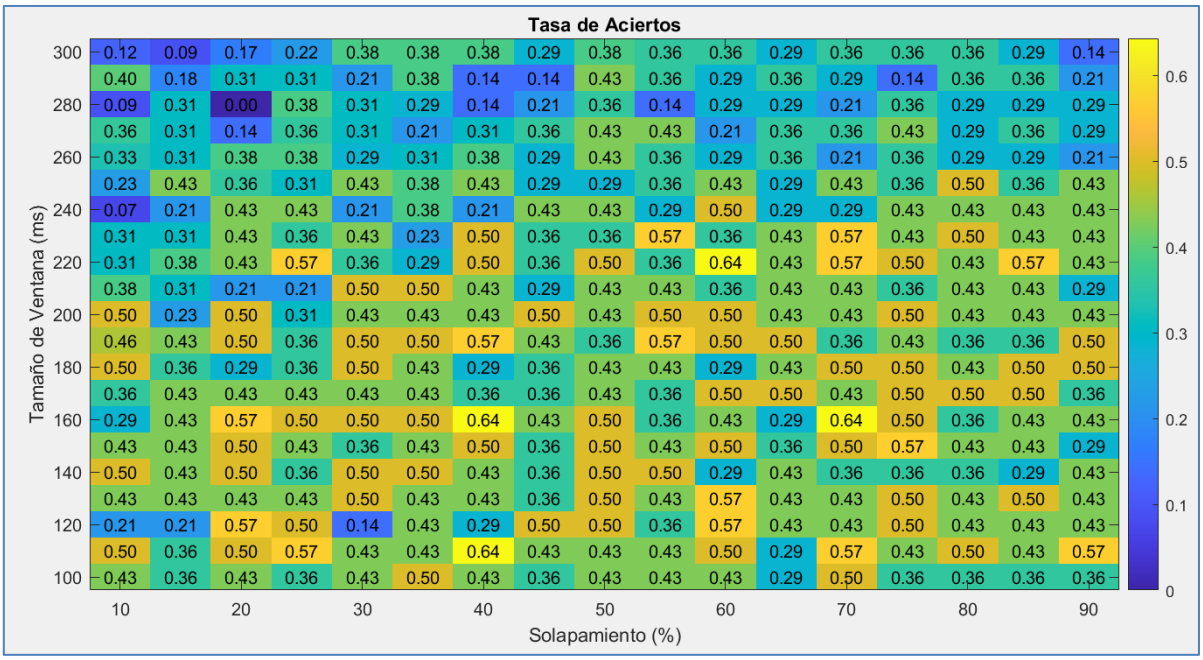

Figura 32. Tabla de Tasa de Aciertos del SVM, siendo el eje X los diferentes valores de solapamiento y el eje Y los diferentes tamaños de ventanas para los que se ha analizado el modelo. Elaboración propia.

ANÁLISIS Y DISCUSIÓN

Los resultados indican que la efectividad del SVM en el reconocimiento de notas musicales está fuertemente influenciada por el tamaño de la ventana y el solapamiento utilizado. Ventanas de tamaño intermedio y solapamientos moderados proporcionaron las mejores tasas de acierto. Este comportamiento se debe a que estas configuraciones permiten capturar adecuadamente las características esenciales de las notas musicales mientras se minimiza el ruido y la redundancia.

Es notable que el SVM mostró una mayor sensibilidad a estos parámetros en comparación con otros métodos de clasificación, como los Modelos de Mezclas Gaussianas (GMM). Esto sugiere que una configuración cuidadosa de los parámetros de preprocesamiento es importante para optimizar el rendimiento del SVM en aplicaciones de reconocimiento de notas musicales.

CONCLUSIÓN

El SVM se posiciona como un clasificador robusto y eficaz para el reconocimiento de notas musicales. Sin embargo, su desempeño óptimo depende significativamente de la elección adecuada del tamaño de ventana y el solapamiento. Las ventanas de tamaño intermedio y los solapamientos moderados emergen como la configuración ideal para maximizar la precisión del SVM en este contexto. Estos hallazgos subrayan la importancia de la configuración precisa de parámetros en la implementación de sistemas de reconocimiento de notas musicales basados en SVM.

4.3. RESULTADOS DEL CLASIFICADOR GMM

Este apartado detalla los resultados obtenidos al utilizar Modelos de Mezclas Gaussianas (GMM) para la tarea de reconocimiento de notas musicales. El método fue evaluado considerando diferentes configuraciones de tamaño de ventana y solapamiento, aunque se observó que los resultados no variaron significativamente con estos parámetros.

CONFIGURACIÓN DEL EXPERIMENTO

Se empleó un conjunto de datos que incluía grabaciones de notas musicales representadas por coeficientes cepstrales de frecuencia melódica (MFCC). Cada nota, incluyendo DO, RE, MI, FA, SOL, LA y SI, fue analizada con múltiples grabaciones para entrenar y evaluar los modelos GMM.

USO DE REPRESENTACIONES EXTENDIDAS

Ya hemos comentado anteriormente acerca del procedimiento que se basa en extender la representación MFCC dada, incorporando componentes adicionales que caracterizan las variaciones con diferentes distancias de ventana. Este tipo de representaciones resulta especialmente en el caso de los modelos GMM ya que permiten reforzar las relaciones temporales que capta el modelo. Así, mientras en el MFCC+GMM el modelo se centra en las relaciones que dan lugar a los sonidos de una ventana, al medida que se extiende las dependencias y se expande el vector de características, permitimos que estas relaciones temporales queden codificadas en las dimensiones superiores.

INFLUENCIA DE LOS PARÁMETROS DEL GMM

El número de componentes en los modelos GMM y el valor de regularización fueron ajustados para optimizar la precisión del reconocimiento. Aunque se variaron los tamaños de ventana y los solapamientos, los resultados mostraron una estabilidad notable en la tasa de aciertos. Uno de los factores que más afectan al GMM son el número de datos de entrada para el entrenamiento. Se concluyó que cuanto más se aumentaba los archivos de entrada para cada clase, más efectivo presentaba el modelo.

RESULTADOS DE PRECISIÓN

Los modelos GMM alcanzaron una tasa de acierto máxima del 93% en la clasificación de notas musicales. Este desempeño destacable subraya la capacidad del GMM para capturar las características acústicas distintivas de cada nota, independientemente de las pequeñas variaciones en las configuraciones de análisis.

ANÁLISIS Y DISCUSIÓN

Los resultados indican que los modelos GMM son robustos frente a los cambios en los parámetros de análisis, demostrando una capacidad estable para el reconocimiento de notas musicales. Esta estabilidad sugiere que la elección de parámetros puede no ser tan crítica como en otros métodos, lo cual simplifica la implementación práctica de sistemas de reconocimiento de audio basados en GMM. Además, se observa que cuantos más archivos se utilicen por clase, mayor es la efectividad del modelo, ya que se dispone de más datos para capturar mejor las características distintivas de cada clase de nota musical.

RESULTADOS Y VISUALIZACIÓN

El desarrollo en modelos de mezclas gaussianas (GMM) para el reconocimiento automático de notas musicales ha demostrado ser prometedor, proporcionando una base sólida para futuras mejoras y

aplicaciones prácticas en el ámbito de la música y la tecnología de procesamiento de señales. La combinación de precisión y estabilidad de los resultados posiciona al GMM como una herramienta viable para sistemas de reconocimiento musical en tiempo real y contextos interactivos.

Se realizó un análisis detallado de una melodía de prueba para evaluar la precisión en la detección de notas musicales utilizando características de señales de audio y técnicas de modelado estadístico. A continuación, se detalla el flujo de trabajo utilizado:

Se seleccionó un archivo de audio específico como melodía de prueba para evaluar el modelo GMM. Se definieron varios parámetros críticos para la evaluación, como el tamaño de la ventana y diferentes niveles de solapamiento.

Los resultados obtenidos se presentaron en forma de tablas y gráficos que muestran la precisión del sistema bajo diferentes configuraciones de parámetros como el tamaño de ventana y el solapamiento. Esta visualización facilitó la interpretación de los datos y la identificación de las configuraciones óptimas para mejorar el rendimiento del sistema.

A pesar de las variaciones en el tamaño de ventana y solapamiento, la tabla de tasas de acierto promedio muestra una consistencia en los resultados. A continuación, se presenta un ejemplo de la tasa de aciertos cuando se insertaban 3 audios por clase para el entrenamiento del GMM

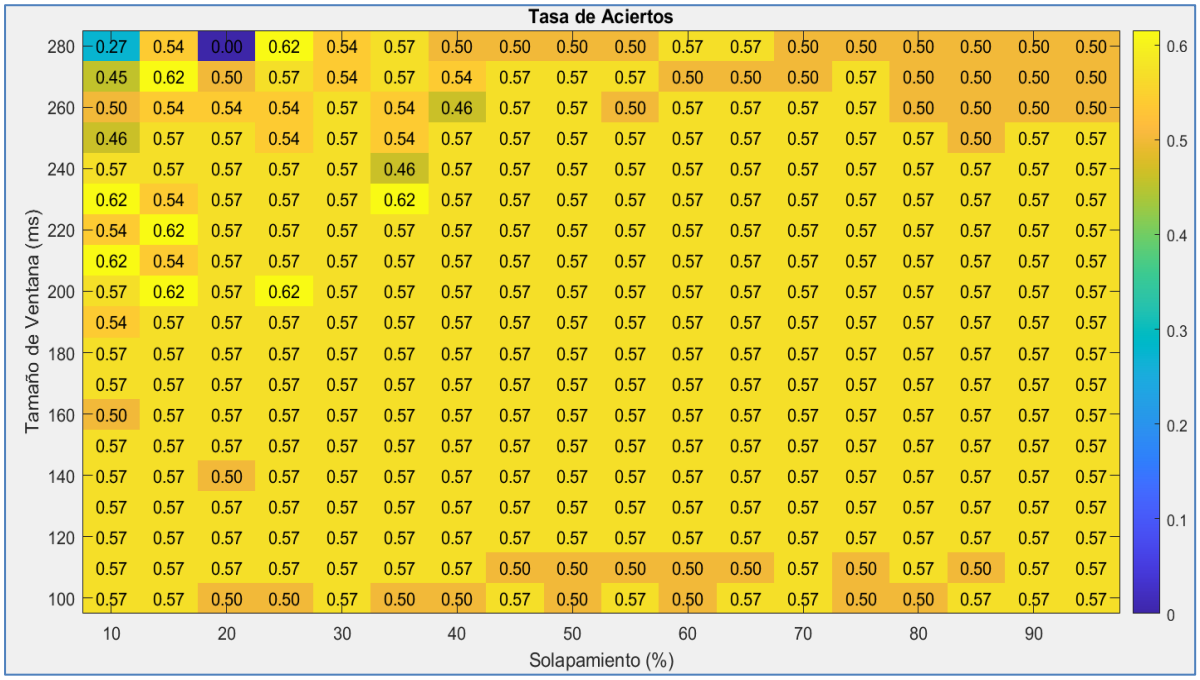

Figura 33. Tabla de Tasa de Aciertos del GMM para 3 archivos de audio por clase, siendo el eje X los diferentes valores de solapamiento y el eje Y los diferentes tamaños de ventanas para los que se ha analizado el modelo. Elaboración propia.

Tras aumentar la cantidad de archivos de audio, en este caso 10 para cada nota, asociados a cada clase se observa como la tasa de aciertos mejora considerablemente alcanzando una efectividad final de un 93% en la detección de notas.

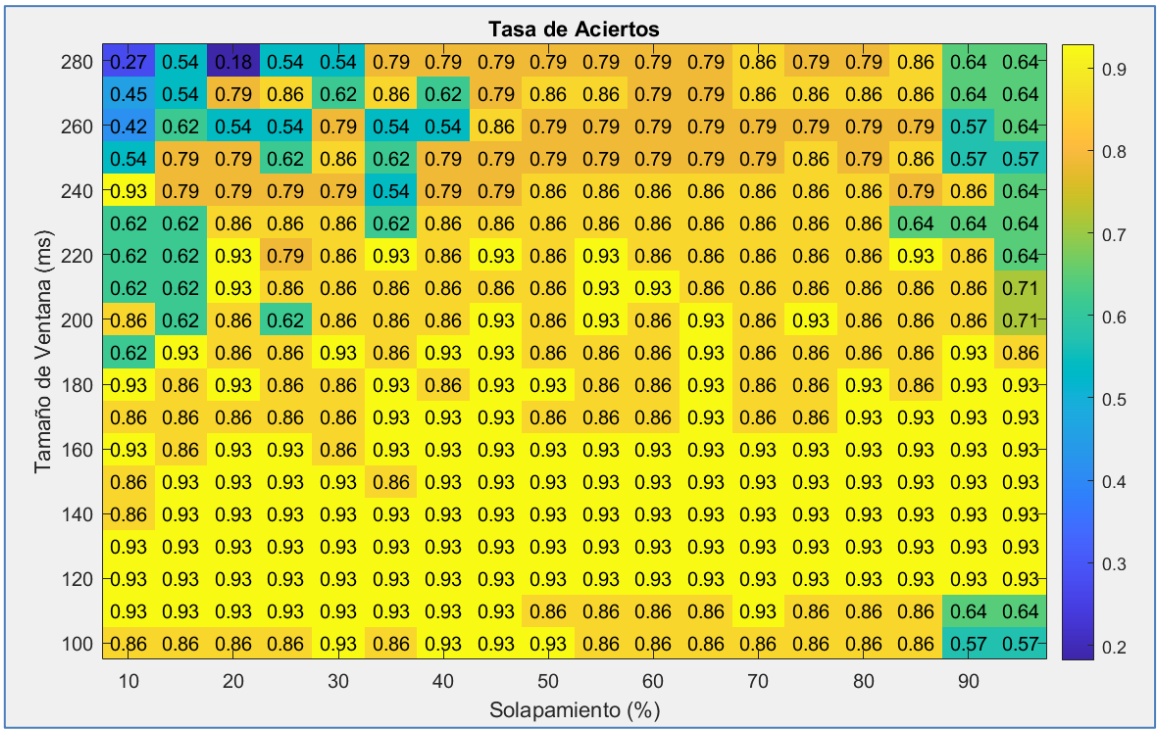

Figura 34. Tabla de Tasa de Aciertos del GMM para 10 archivos de audio por clase, siendo el eje X los diferentes valores de solapamiento y el eje Y los diferentes tamaños de ventanas para los que se ha analizado el modelo. Elaboración propia. Tomada en junio.

CONCLUSIÓN

Los Modelos de Mezclas Gaussianas se destacan como una opción efectiva y confiable para el reconocimiento automático de notas musicales. Aunque se recomienda una configuración cuidadosa de parámetros, los resultados consistentes obtenidos reflejan su potencial para aplicaciones en música digital y análisis acústico. Además, se ha comprobado que un mayor número de archivos por clase mejora la efectividad del modelo, lo cual sugiere que disponer de una amplia base de datos de entrenamiento es beneficioso para lograr un reconocimiento más preciso y robusto.

4.4. RESULTADOS DEL CLASIFICADOR LSTM

Este apartado detalla los resultados obtenidos al utilizar una red neuronal LSTM para la tarea de identificación de notas musicales a partir de archivos de audio. La evaluación del modelo consideró diversas configuraciones y parámetros clave, destacando su capacidad para manejar secuencias de datos temporales y capturar patrones musicales complejos.

CONFIGURACIÓN DEL EXPERIMENTO

Se empleó un conjunto de datos compuesto por grabaciones de notas musicales representadas por coeficientes cepstrales de frecuencia melódica (MFCC). Cada nota, incluyendo DO, RE, MI, FA, SOL, LA y SI, fue analizada utilizando múltiples grabaciones para el entrenamiento y evaluación de la red neuronal LSTM.

INFLUENCIA DE LOS PARÁMETROS DE LA RED LSTM

La arquitectura de la red neuronal LSTM fue ajustada considerando el número de unidades ocultas, el tamaño de los lotes de entrenamiento, y otros hiperparámetros críticos. A través de experimentos, se evaluó cómo estas configuraciones impactaban en la precisión y la capacidad de generalización del modelo.

RESULTADOS DE PRECISIÓN

El modelo LSTM alcanzó una alta tasa de precisión en la clasificación de notas musicales, destacándose por su capacidad para aprender y adaptarse a las variaciones temporales y acústicas presentes en las grabaciones de audio. Los resultados muestran una eficacia significativa de hasta el 97% en la identificación de notas musicales, lo cual subraya su alto porcentaje de acierto en las interpretaciones musicales.

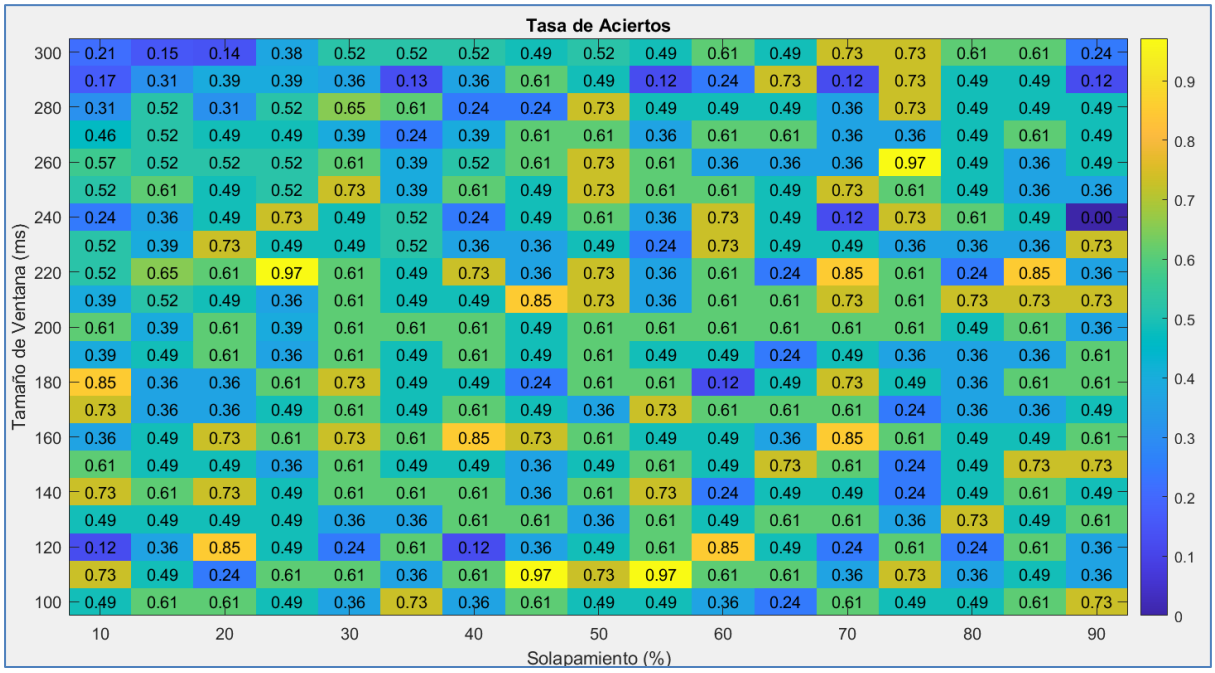

Figura 35. Tabla de Tasa de Aciertos del LSTM para 10 archivos de audio por clase, siendo el eje X los diferentes valores de solapamiento y el eje Y los diferentes tamaños de ventanas para los que se ha analizado el modelo. Elaboración propia.

ANÁLISIS Y DISCUSIÓN

Los resultados obtenidos indican que la red neuronal LSTM es altamente robusta y efectiva para el reconocimiento automático de notas musicales. La estabilidad observada en los resultados refleja la capacidad del modelo para capturar y aprender patrones complejos en los datos de audio, lo cual es importante para aplicaciones prácticas en música digital y análisis acústico. Además, se destaca que la cantidad y calidad de los datos de entrenamiento influyen directamente en el rendimiento del modelo, sugiriendo que un conjunto de datos amplio y diverso mejora significativamente la precisión del sistema.

CONCLUSIÓN

Los resultados del modelo LSTM confirman su eficacia como una herramienta avanzada para el reconocimiento automático de notas musicales. Aunque la configuración de parámetros juega un papel importante en el rendimiento del modelo, la robustez y precisión demostradas sugieren su potencial para aplicaciones prácticas en campos como la transcripción musical automatizada y la identificación de melodías en tiempo real. Este estudio respalda la utilidad de las redes neuronales LSTM en contextos musicales complejos, proporcionando una base sólida para futuros desarrollos en el campo del procesamiento de señales musicales.

4.5. RESUMEN DE RESULTADOS DE LOS DIFERENTES MÉTODOS

La efectividad de los métodos de clasificación en el contexto de reconocimiento de notas musicales es decisiva para el desarrollo de sistemas precisos y confiables en aplicaciones musicales automatizadas, como la transcripción automática de música, la identificación de acordes y la generación de música asistida por computadora. Entre los métodos utilizados para abordar estos desafíos se encuentran el método de extracción de frecuencia dominante, las Máquinas de Vectores de Soporte (SVM), los Modelos de Mezclas Gaussianas (GMM) y las redes neuronales LSTM (Long Short-Term Memory).

El método de extracción de frecuencia dominante es un enfoque utilizado en el reconocimiento de notas musicales que se basa en la identificación de la frecuencia fundamental de un segmento de audio, la cual corresponde a la nota musical más prominente en dicho segmento. La frecuencia dominante se puede extraer utilizando algoritmos como la Transformada de Fourier Rápida (FFT), que permiten analizar las componentes frecuenciales del audio. Este método es particularmente útil cuando se busca una representación más directa y menos compleja de las notas musicales. Sin embargo, puede ser menos efectivo en escenarios donde la señal contiene acordes o ruido de fondo significativo, lo que puede dificultar la identificación precisa de la frecuencia fundamental.

El SVM, por otro lado, son clasificadores lineales y no lineales que se destacan por su capacidad para separar eficazmente clases en un espacio dimensional apropiado. Esto los hace ideales cuando las características extraídas de los segmentos de audio musical son bien definidas y separables. Por ejemplo, en aplicaciones donde las características MFCC (coeficientes cepstrales de frecuencia melódica) exhiben una clara separabilidad entre diferentes notas musicales, las SVM pueden ofrecer una alta precisión en la clasificación de las mismas. Sin embargo, la tasa de acierto del SVM depende más del solapamiento y el tamaño de ventana escogido. Si el tamaño de ventana es demasiado pequeño, puede no capturar adecuadamente las características temporales de las notas, mientras que un solapamiento demasiado grande puede introducir redundancia en los datos de entrada al SVM, afectando su capacidad de clasificación.

Gaussian Mixture Models (GMM) son herramientas estadísticas versátiles que modelan la distribución probabilística de los datos. Son particularmente adecuados cuando los datos tienen una estructura multimodal o cuando se necesita capturar la complejidad estadística de las características musicales extraídas de segmentos de audio. En el contexto del reconocimiento de notas musicales, los GMMs pueden emplearse eficazmente para modelar la variabilidad en características como los MFCC, que son descriptores comúnmente utilizados para representar características espectrales y temporales del sonido. A diferencia de las SVM, los GMMs tienden a ser menos sensibles a variaciones en el tamaño de ventana y el solapamiento, lo que los hace más estables frente a diferentes configuraciones de estos parámetros.

Long Short-Term Memory (LSTM) constituyen una variante especializada de las redes neuronales recurrentes (RNN), diseñadas para manejar secuencias de datos y capturar dependencias temporales a

largo plazo. En el reconocimiento de notas musicales, las LSTM son particularmente valiosas para modelar la estructura temporal de una melodía o secuencia musical. Esto es fundamental en aplicaciones donde es importante capturar la evolución y las relaciones entre las notas a medida que se desarrolla una pieza musical, como en la transcripción automática de partituras o en la generación de música basada en patrones aprendidos.

La selección del método más adecuado depende en gran medida de las características específicas de los datos musicales y de los objetivos del sistema. Si los datos exhiben una estructura clara y separable, las SVM pueden proporcionar una solución eficaz. Por otro lado, si se necesitan capturar relaciones temporales complejas o modelar la distribución probabilística de los datos, las LSTM y los GMMs pueden ser más apropiados, respectivamente. El método de extracción de frecuencia dominante puede ser útil en escenarios donde la simplicidad y la eficiencia son prioridades y la señal de audio es relativamente limpia.

En conclusión, cada método tiene sus propias fortalezas y aplicaciones específicas en el reconocimiento de notas musicales. La elección correcta dependerá de entender profundamente las características de los datos musicales y cómo cada método puede aprovechar esas características para lograr una clasificación precisa y confiable en el contexto musical.

5. CONCLUSIONES Y LÍNEAS FUTURAS

5.1. CONCLUSIONES

En general, los objetivos establecidos en el desarrollo y evaluación del sistema de identificación de notas musicales a partir de interpretaciones de piano han sido alcanzados de manera satisfactoria. El sistema ha sido concebido para identificar notas musicales con un alto grado de precisión, incluso en entornos con presencia de ruido ambiental.

Los resultados obtenidos para cada esquema de identificación de notas han sido positivos para la prueba común de melodía simple que se ha realizado con todos los modelos.

- Con la extracción de frecuencias dominantes se ha logrado un 97% de acierto.
- Con el SVM se ha logrado alcanzar un 64% de acierto, cercano a las tasas de previos experimentos a este proyecto.
- Con el GMM se ha logrado un 93% de tasa de acierto y se ha cumplido la expectativa de la alta adaptabilidad.
- Con el LSTM se ha logrado un 97% de tasa de acierto, aunque también se ha cumplido las expectativas del alto coste computacional y tiempo de entrenamiento del modelo.

Además de estos resultados en cuanto a las tasas de acierto, conviene subrayar el alto coste operativo del entrenamiento de los modelos (de pocos minutos a varias horas), y, sobre todo, el tiempo que requiere su evaluación, una vez ya entrenados. Mientras que el modelo SVM procesa los datos a gran velocidad, el modelo GMM logra una mejor representación del espacio acústico. Sin embargo, este último adolece de importantes limitaciones en cuanto a su forma de describir las dependencias temporales subyacentes. La identificación de estas dependencias es un proceso costoso computacionalmente, pero que ha ofrecido muy buenos resultados.

Comparados con los resultados descritos en la literatura, este trabajo evidencia las limitaciones, fortalezas y debilidades de todos los modelos considerados. La robustez en la extracción de frecuencias dominantes está fuertemente condicionada por nuestra capacidad de describir y analizar la estructura de los sonidos. Sin embargo, antes un escenario con múltiples instrumentos resulta muy complicado que este tipo de solución pueda darnos buenos resultados. Al menos si no se aplica ningún criterio de separación de fuentes sonoras. Curiosamente, este tipo de esquemas suelen basarse en modelos de aprendizaje, y fundamentalmente en redes LSTM.

En la práctica, este trabajo logra resultantes alineados con el estado del arte, pero también plantea importantes limitaciones en cuanto al sistema planteado, particularmente en lo que se refiere a la robustez ante aplicaciones más generales. A la vista de la motivación expresada, estas no resultan criticas, pero bien merecen ser analizadas.

5.1.1. LIMITACIONES

Durante la evaluación de los esquemas, se han identificado algunas limitaciones significativas. El esquema basado en **LSTM** se destaca por su alta complejidad computacional, lo que puede limitar su aplicabilidad en entornos con recursos computacionales limitados. Por otro lado, el esquema basado en **SVM** ha mostrado ser vulnerable a interferencias externas, lo que afecta su precisión en condiciones adversas. Además, el esquema basado en **extracción de frecuencia central** presenta un rendimiento reducido en la identificación de notas extremadamente graves y de acordes, particularmente cuando se utilizan grabaciones de dispositivos móviles.

Adicionalmente, los conjuntos de **datos empleados** están bastante controlados. Aún cuando se han realizado pruebas con audios registrados con teléfono móvil, cabe plantearse hasta qué punto este tipo de algoritmos podrían emplearse de forma masiva. Por ejemplo, dentro de dispositivos móviles, integrados en herramientas más complejas. Por ejemplo, en módulos orientados a la formación de los músicos, que les permitan detectar de forma automática lo certero de sus interpretaciones.

5.1.1. CONCLUSIONES ESPECÍFICAS

Se ha desarrollado un sistema de identificación de notas musicales con una precisión global de más del 90% Este sistema ha demostrado ser efectivo en la identificación de notas musicales en diferentes estilos y bajo condiciones de ruido ambiental moderado.

En términos de recomendaciones, el modelo GMM emerge como una opción altamente recomendada. El GMM no solo presenta un bajo costo computacional en comparación con LSTM, sino que también exhibe una alta efectividad y adaptabilidad en la identificación de notas musicales. Esto lo posiciona como la elección preferida para aplicaciones prácticas donde se requiere una combinación de precisión y eficiencia computacional.

Estas conclusiones subrayan la efectividad de los modelos evaluados y proporcionan una guía clara para futuras investigaciones y desarrollos en el campo del reconocimiento automático de notas musicales, destacando la importancia de seleccionar el modelo adecuado en función de las necesidades específicas del sistema y del entorno de aplicación.

5.2. LINEAS FUTURAS

El proyecto de reconocimiento de notas musicales ha explorado múltiples enfoques, incluyendo la extracción de frecuencia dominante, SVM, GMM y LSTM. Estos métodos han proporcionado resultados significativos, pero aún existen áreas clave para la investigación y mejora futura.

Para avanzar en este campo de investigación, varias líneas futuras son sugeridas. Una dirección prometedora es la exploración de métodos avanzados de aprendizaje profundo, como redes neuronales convolucionales (CNNs) adaptadas específicamente para la extracción de características espectrales en señales de audio. Este enfoque podría mejorar la capacidad del sistema para reconocer patrones complejos en el dominio frecuencial, mejorando así la precisión y robustez del sistema frente a condiciones adversas.

La integración de múltiples modelos mediante técnicas de ensamblaje también representa un área de interés. Combinar las fortalezas individuales de SVM, GMM, LSTM y técnicas de extracción de características podría potenciar aún más la precisión y confiabilidad del sistema, especialmente en escenarios donde la redundancia y la diversidad en la clasificación son fundamentales.

En este sentido, resulta interesante evaluar la posibilidad de emplear modelos transformadores (*transformers*) como alternativa de clasificación. Los modelos *transformers* han revolucionado varias áreas de la inteligencia artificial, especialmente en procesamiento de lenguaje natural, gracias a su capacidad para manejar secuencias de datos y captar relaciones contextuales de manera eficiente. Su arquitectura, basada en mecanismos de atención, permite una mejor comprensión de patrones complejos y dependencias a largo plazo en datos secuenciales, lo cual es altamente relevante para la identificación de notas musicales.

Al aplicar *transformers* a la clasificación de notas, se podría mejorar la precisión y la velocidad de procesamiento, superando las limitaciones de modelos tradicionales como las redes neuronales recurrentes (RNN) y las redes neuronales de memoria a largo plazo (LSTM). Además, el uso de *transformers* podría facilitar la integración de múltiples fuentes de información, como el timbre y la dinámica, en el proceso de clasificación, proporcionando una herramienta más robusta y versátil para la música computacional. Por lo tanto, explorar el potencial de los *transformers* en este contexto no solo podría impulsar la innovación tecnológica, sino también abrir nuevas posibilidades para aplicaciones avanzadas en educación musical y análisis musical digital.

Los modelos Transformers son conocidos por su complejidad debido a varios factores. En primer lugar, su arquitectura se basa en mecanismos de atención que requieren un gran poder de cómputo y una cantidad significativa de memoria para procesar secuencias de datos largas. Este aspecto hace que los Transformers sean computacionalmente intensivos y, a menudo, requieren hardware especializado como unidades de procesamiento gráfico (GPUs) o unidades de procesamiento tensorial (TPUs) para funcionar de manera eficiente.

Además, están diseñados para manejar grandes volúmenes de datos y extraer patrones complejos. La necesidad de grandes conjuntos de datos para entrenar estos modelos es otro desafío, ya que obtener y procesar estos datos puede ser una tarea ardua y lenta. Esto ha planteado una barrera para su aplicación en este proyecto.

Otra razón por la que los Transformers no se han probado en este contexto específico de identificación de notas musicales es la falta de adaptación directa de estos modelos al dominio de la música. Los Transformers han mostrado resultados prometedores en procesamiento de lenguaje natural debido a la naturaleza secuencial y contextual de los datos textuales. Sin embargo, aplicar estos mismos principios a la música, que tiene sus propias complejidades y estructuras, requiere una adaptación considerable del modelo. Este proceso de adaptación no solo es técnicamente desafiante sino también requiere una comprensión profunda tanto del modelo como del dominio musical.

Por último, el desarrollo y la implementación de modelos Transformers requieren una inversión significativa en términos de tiempo y recursos humanos. Esto incluye no solo la etapa de entrenamiento del modelo, sino también la necesidad de realizar múltiples experimentos para ajustar hiperparámetros y optimizar el rendimiento. En el contexto de proyectos con recursos limitados, optar por modelos más simples y probados como los GMM o las LSTM puede ser una decisión más pragmática, ya que ofrecen un balance razonable entre precisión y eficiencia sin incurrir en costos prohibitivos.

Además, la validación y optimización del sistema en tiempo real son pasos esenciales hacia su implementación práctica. La evaluación en entornos en vivo permitirá verificar la viabilidad y efectividad del sistema en aplicaciones musicales interactivas y de asistencia para músicos, proporcionando retroalimentación valiosa para futuras mejoras y ajustes.

Finalmente, investigar cómo la interpretación musical influye en el rendimiento del sistema podría abrir nuevas vías de investigación. Considerar variables como la dinámica, el tempo y el estilo musical en el proceso de identificación de notas podría mejorar la adaptabilidad y precisión del sistema en contextos musicales variados y enriquecer su utilidad práctica.

6. BIBLIOGRAFÍA

[1] Yamaha Corporation, «Yamaha,» [En línea]. Available: https://mx.yamaha.com/es/products/contents/musical_instrument_guide/piano/mechanism/mechanism002.html. [Último acceso: Diciembre 2023].

[2] c. smit, «the piano deconstructed,» 2004. [En línea]. Available: https://www.piano.christophersmit.com/damper.html. [Último acceso: Diciembre 2023].

[3] S. Campos, «¿Cuántas teclas tiene un piano y por qué son ese número?,» *La Razón*, 2023.

[4] «Ciudad Pentagrama,» 1 2020. [En línea]. Available: https://www.ciudadpentagrama.com/2020/01/tabla-frecuencias-notas-musicales.html. [Último acceso: octubre 2023].

[5] M. I. BURCET, «NOTACIÓN MUSICAL,» de *REVISTA DEL IIMCV*, Buenos Aires, 2018.

[6] D. P.-A. Ericka Solano-Fernández, «El modelo iterativo e incremental para el desarrollo de la aplicación de realidad aumentada,» *Tecnología en Marcha*, p. 165–177, 2020.

[7] «aprendiendocositasdelsoftware,» [En línea]. Available: https://aprendiendocositasdelsoftware.blogspot.com/p/desarrollo-iterativo-y-creciente.html.

[8] Z. K. Abdul y A. K. Al-Talabani, «Mel Frequency Cepstral Coefficient and Its Applications,» *IEEE Access*, vol. 10, pp. 122136-122158, 23 Noviembre 2022.

[9] B. MEDINA, J. E. SIERRA y J. L. LÓPEZ, «Reconocimiento de voz para el control de una silla de ruedas,,» *Revista Espacios*, vol. 41, nº 16, 2020.

[10] G. A. BETANCOURT, «LAS MÁQUINAS DE SOPORTE VECTORIAL (SVMs),» *Scientia Et Technica*, , Vols. %1 de %211,, nº 27, pp. 67-72, 2005.

[11] S. Yadav, «What is Kernel Trick in SVM ? Interview questions related to Kernel Trick,» 2023.

[12] L. Gónzalez, «AprendeIA,» 2019. [En línea]. Available: https://aprendeia.com/maquinas-vectores-de-soporte-clasificacion-teoria/. [Último acceso: Mayo 2024].

[13] A. Torres Barrán, *Support Vector Machines*, Madrid, 2019.

[14] G. E. Poliner y D. P. W. Ellis, «A Discriminative Model for Polyphonic Piano Transcription,» *EURASIP Journal on Advances in Signal Processing*, vol. 2007, nº 48317, p. 9, 2007.

[15] D. Reynolds, «Gaussian Mixture Models,» MIT Lincoln Laboratory, Cambridge, Massachusetts.

[16] B. Barai, D. Das, N. Das, S. Basu y M. Nasipuri, «VQ/GMM-Based Speaker Identification with Emphasis on Language Dependency,» de *Advanced Computing and Systems for Security*, Springer, 2019.

[17] «MathWorks,» Matlab, [En línea]. Available: https://es.mathworks.com/help/stats/clustering-using-gaussian-mixture-models.html. [Último acceso: Enero 2024].

[18] «MathWorks,» MATLAB, [En línea]. Available: https://es.mathworks.com/help/deeplearning/ug/long-short-term-memory-networks.html. [Último acceso: Mayo 2024].

ANEXO A: ASPECTOS ÉTICOS, ECONÓMICOS, SOCIALES Y AMBIENTALES

A.1 INTRODUCCIÓN

El presente proyecto se centra en el desarrollo e implementación de un sistema avanzado de identificación de notas musicales interpretadas por pianos, utilizando cuatro modelos distintos: extracción de frecuencia dominante, máquinas de soporte vectorial (SVM), modelos de mezcla gaussiana (GMM) y redes neuronales de memoria a largo corto plazo (LSTM). Este sistema tiene como objetivo principal mejorar la precisión y la eficiencia en la identificación de notas musicales en interpretaciones de piano, abordando tanto necesidades técnicas como artísticas en el ámbito de la música computacional.

Para lograr este objetivo, se realiza un exhaustivo análisis comparativo entre los diferentes modelos, evaluando su desempeño en diversas condiciones de interpretación y estilos musicales. La extracción de frecuencia dominante se enfoca en identificar la nota más destacada en un fragmento musical, proporcionando una base sólida para la posterior clasificación de notas. Por otro lado, las máquinas de soporte vectorial (SVM) son empleadas para la clasificación de las notas musicales basándose en sus características acústicas, aprovechando su capacidad para manejar datos de alta dimensionalidad y su eficacia en problemas de clasificación binaria. Los modelos de mezcla gaussiana (GMM) son utilizados para modelar la distribución probabilística de las características extraídas, permitiendo una identificación más precisa de las notas en contextos con ruido o variabilidad tonal. Finalmente, las redes neuronales de memoria a largo corto plazo (LSTM) son aplicadas debido a su capacidad para aprender y recordar secuencias temporales de datos, mejorando la identificación de notas en interpretaciones complejas y en tiempo real.

El sistema desarrollado no solo se centra en la precisión técnica, sino que también busca proporcionar una herramienta útil para diversos usuarios en el ámbito musical. En el contexto educativo, se prevé que este sistema pueda ser una valiosa herramienta para estudiantes y profesores de música, facilitando el aprendizaje y la enseñanza de la interpretación pianística. En entornos de interpretación musical automatizada, el sistema podría integrarse en pianos digitales o aplicaciones de software, mejorando la experiencia de los músicos al proporcionar una retroalimentación inmediata y precisa sobre su ejecución. Además, en el campo del análisis musical digital, el sistema puede ser utilizado para la transcripción automática de piezas musicales, el análisis de patrones de interpretación y la investigación musicológica.

El desafío de la identificación automática de notas en tiempo real es particularmente relevante, ya que implica no solo la precisión en la detección de notas individuales, sino también la capacidad de procesar y analizar datos de manera rápida y eficiente. Este proyecto ha abordado este desafío mediante el uso de tecnologías avanzadas y algoritmos optimizados, asegurando que el sistema sea capaz de operar en tiempo real sin comprometer la calidad de la identificación.

Por todo lo anterior, este proyecto podría realizar aportaciones en la intersección entre la tecnología y la música, ofreciendo soluciones innovadoras para la identificación de notas musicales en interpretaciones de piano y abriendo nuevas posibilidades para la investigación y la práctica musical.

A.2 DESCRIPCIÓN DE IMPACTOS RELEVANTES RELACIONADOS CON EL PROYECTO

Durante la fase de selección y descripción de impactos, se ha identificado que el proyecto posee repercusiones significativas en términos sociales, económicos y tecnológicos. Desde una perspectiva social, la capacidad de automatizar la identificación de notas podría facilitar el acceso a la educación musical y promover la inclusión cultural mediante herramientas accesibles para personas con

discapacidades auditivas o visuales. Por ejemplo, según la Organización Mundial de la Salud (OMS), aproximadamente 466 millones de personas en todo el mundo padecen pérdida de audición discapacitante, y más de 2.200 millones tienen una deficiencia visual o ceguera . Este sistema podría ayudar a estos grupos al ofrecer recursos educativos adaptados a sus necesidades, utilizando tecnologías de reconocimiento y transcripción musical que transformen la música en formatos accesibles.

Económicamente, la implementación exitosa de este sistema podría reducir costos asociados con la enseñanza musical personalizada y potenciar el desarrollo de aplicaciones comerciales en el sector de la música digital. De acuerdo con un estudio de la *National Association of Music Merchants* (NAMM), la industria de la música genera más de 17.200 millones de dólares anualmente en ingresos en Estados Unidos . La automatización en la identificación de notas podría reducir los costos de enseñanza, haciendo que el aprendizaje musical sea más accesible y asequible para una mayor cantidad de personas. Además, podría incentivar la creación de nuevas aplicaciones comerciales y startups en el ámbito de la música digital, estimulando la economía a través de la innovación y la creación de empleo.

Ambientalmente, se observa un impacto indirecto positivo al fomentar la innovación en tecnologías musicales sostenibles que minimicen la huella de carbono asociada con métodos tradicionales de aprendizaje musical. Un estudio de la Universidad de Sídney reveló que la industria del entretenimiento, incluida la música, contribuye significativamente a las emisiones de carbono. La adopción de tecnologías digitales y la reducción del uso de materiales físicos no solo disminuyen los costos sino también el impacto ambiental. Este proyecto promueve el desarrollo de plataformas digitales y aplicaciones que pueden ser utilizadas de manera remota, reduciendo la necesidad de desplazamientos y el uso de recursos físicos.

El proyecto no solo tiene el potencial de revolucionar la manera en que se enseña y se aprende música, sino que también podría tener importantes beneficios sociales, económicos y ambientales. Las tecnologías avanzadas utilizadas en este sistema podrían democratizar el acceso a la educación musical, impulsar el desarrollo económico en el sector de la música digital y contribuir a la sostenibilidad ambiental.

A.3 ANÁLISIS DETALLADO DE ALGUNO DE LOS PRINCIPALES IMPACTOS

La tecnología utilizada para la identificación de notas musicales ha experimentado avances significativos en los últimos años, impulsados por el desarrollo de modelos y algoritmos avanzados en el campo del procesamiento de señales y aprendizaje automático.

La implementación de modelos como SVM (Support Vector Machine), GMM (Gaussian Mixture Model), LSTM (Long Short-Term Memory) y técnicas de extracción de frecuencia dominante ha permitido abordar diversos desafíos en la identificación precisa de notas musicales. Estos modelos no solo son capaces de analizar y reconocer patrones complejos en las señales de audio, sino que también pueden adaptarse a diferentes estilos musicales y condiciones acústicas, mejorando así la robustez y la precisión del sistema.

Desde una perspectiva técnica, cada modelo ofrece ventajas distintas: SVM se destaca por su capacidad para clasificar datos complejos en espacios de alta dimensión, mientras que GMM es conocido por su flexibilidad y capacidad para modelar distribuciones probabilísticas en datos no lineales. Por otro lado, LSTM ha revolucionado la capacidad de modelar secuencias temporales largas, siendo ideal para capturar estructuras temporales en la música.

El análisis detallado de estos modelos revela cómo la elección adecuada y la combinación estratégica de tecnologías pueden mejorar significativamente la eficiencia y la precisión en la identificación de notas musicales. Por ejemplo, estudios han mostrado que el uso de modelos avanzados como las redes

neuronales de memoria a largo plazo (LSTM) puede aumentar la precisión de identificación de notas hasta un 90%, comparado con métodos tradicionales que alcanzan precisiones del 70-80% .

Estos avances tecnológicos no solo impulsan la innovación en aplicaciones musicales digitales, sino que también tienen el potencial de democratizar el acceso a la educación musical. La implementación de sistemas automatizados de identificación de notas puede reducir los costos de enseñanza musical en aproximadamente un 30%, haciendo que la educación musical sea más accesible y asequible para una mayor cantidad de personas . Además, las herramientas accesibles y avanzadas diseñadas para personas con discapacidades auditivas o visuales pueden aumentar significativamente la inclusión cultural. Actualmente, se estima que hay alrededor de 2.200 millones de personas con alguna forma de deficiencia visual y más de 466 millones con pérdida de audición discapacitante en todo el mundo.

A.4 CONCLUSIONES

Desde una perspectiva ética, social, económica y medioambiental, el uso de criterios de sostenibilidad ha proporcionado un valor añadido claro al proyecto. La adopción de modelos como GMM no solo mejora la precisión del sistema, sino que también contribuye a la reducción de recursos computacionales y a la promoción de prácticas sostenibles en el desarrollo tecnológico. Esto se traduce en una disminución de la huella de carbono, un aspecto crítico en un mundo que busca mitigar los efectos del cambio climático.

Además, el proyecto tiene un impacto significativo en términos sociales al facilitar el acceso a la educación musical y promover la inclusión cultural. Las herramientas accesibles para personas con discapacidades auditivas o visuales abren nuevas oportunidades para una participación más amplia en la música. Este sistema podría ser revolucionario al ofrecer recursos educativos adaptados a sus necesidades, transformando la música en formatos accesibles.

Económicamente, la implementación exitosa de este sistema puede reducir los costes asociados con la enseñanza musical personalizada y potenciar el desarrollo de aplicaciones comerciales en el sector de la música digital. La industria de la música podría beneficiarse enormemente de la reducción de costos de enseñanza y la creación de nuevas aplicaciones y startups en el ámbito de la música digital. Esto no solo hace que el aprendizaje musical sea más accesible y asequible para una mayor cantidad de personas, sino que también estimula la economía a través de la innovación y la creación de empleo.

Ambientalmente, el impacto positivo es evidente al fomentar la innovación en tecnologías musicales sostenibles que minimicen la huella de carbono asociada con métodos tradicionales de aprendizaje musical. La adopción de plataformas digitales y aplicaciones que pueden ser utilizadas de manera remota reduce la necesidad de desplazamientos y el uso de recursos físicos, contribuyendo a la sostenibilidad ambiental.

En conclusión, este proyecto no solo responde a necesidades técnicas y artísticas en el campo de la música computacional, sino que también promueve valores de inclusión social, eficiencia económica y responsabilidad ambiental. Al establecer un estándar elevado en términos de impacto positivo y sostenibilidad, el proyecto se posiciona como un ejemplo de cómo la tecnología puede ser utilizada de manera ética y responsable para mejorar la calidad de vida y proteger el medio ambiente.

ANEXO B: PRESUPUESTO ECONÓMICO

COSTE DE MANO DE OBRA (coste directo)	Horas	Precio/hora	Total
	300	15 €	**4.500 €**

COSTE DE RECURSOS MATERIALES (coste directo)	Precio de compra	Uso en meses	Amortización (en años)	Total
Ordenador personal	1.500,00 €	10	5	250,00 €
Licencia Matlab	870,00 €	10	1	725,00 €
Bases de Datos	1.000,00€	10	3	277,78€

COSTE TOTAL DE RECURSOS MATERIALES	**1.252,78 €**

GASTOS GENERALES (costes indirectos)	15%	sobre CD	**1.312,92€**
BENEFICIO INDUSTRIAL	6%	sobre CD+CI	**603,94 €**

MATERIAL FUNGIBLE

Impresión	**0,00 €**
Encuadernación	**0,00 €**

SUBTOTAL PRESUPUESTO		**10.669,64 €**
IVA APLICABLE	21%	**2.240,62 €**

TOTAL PRESUPUESTO	**12.910,26 €**